

Sistema de Agricultura de Precisão para o Manejo Sustentável de Recursos Hídricos baseado na Fusão de Dados de Sensores IoT e Imagens de Satélite

Fernando Daniel Marcelino

Orientadora: Profa. Dra. Fernanda Quelho Rossi

Universidade Federal de São Paulo – UNIFESP
Instituto de Ciência e Tecnologia
Bacharelado em Engenharia de Computação

8 de Dezembro de 2025

Sumário

- 1 Introdução
- 2 Definição do Problema e Objetivos
- 3 Materiais e Métodos
- 4 Resultados
- 5 Conclusões e Trabalhos Futuros

Contexto e motivação

- Pressão sobre os recursos hídricos:
 - Aumento da **demand**a global por alimentos
 - **Escassez e distribuição desigual** de água
 - **Impactos ambientais** da agricultura intensiva
- Desafio: produzir mais com **menor desperdício de água e menor impacto ambiental**
- Alinhamento com a Agenda 2030 da ONU:
 - ODS 2 – Fome Zero e Agricultura Sustentável
 - ODS 6 – Água Potável e Saneamento
 - ODS 12 – Consumo e Produção Responsáveis

Desafios no manejo hídrico

- Manejo da irrigação muitas vezes baseado em:
 - **Experiência empírica** do produtor
 - **Informações dispersas e pouco integradas**
- Riscos associados:
 - Superirrigação ⇒ **desperdício de água, energia e fertilizantes**
 - Subirrigação ⇒ **estresse hídrico e perda de produtividade**
- Necessidade de **ferramentas de apoio à decisão** com visão espaço–temporal do uso de água no talhão

Tecnologias habilitadoras

- **Internet das Coisas (IoT):**

- Sensores de **umidade do solo, temperatura/umidade do ar, vazão, pressão**, etc.
- Medições de **alta frequência temporal** diretamente no campo

- **Sensoriamento remoto (SR):**

- **Imagens multiespectrais** (Sentinel-2, Landsat 8/9, HLS) e **SAR** (Sentinel-1)
- **Visão** espacialmente **contínua** da área cultivada

- **Aprendizado de máquina:**

- Modelos para **estimar indicadores de estado hídrico**
- Geração de **mapas de recomendação de irrigação** em **nível de talhão**

Lacuna na literatura

- Trabalhos em IoT na agricultura:
 - Foco em arquiteturas de **monitoramento e automação** de irrigação
 - Ênfase em **sensores de campo** e lógica de decisão local
- Trabalhos em sensoriamento remoto e aprendizado de máquina:
 - Estimativa de **evapotranspiração, umidade do solo, uso de água e zonas de manejo**
- Porém:
 - Poucas propostas descrevem **arquiteturas completas** que integrem **séries temporais de sensores IoT e produtos orbitais** em um fluxo operacional para apoio à decisão em irrigação

Definição do problema

- Adoção de IoT e sensoriamento remoto ocorre, em geral, de forma **fragmentada**
- Ausência de metodologias consolidadas de **fusão de dados** que conciliem:
 - Alta frequência temporal dos sensores de campo
 - Cobertura espacial e multiespectral das imagens de satélite

Questão Central

Como integrar, de forma sistemática, dados de sensores IoT e imagens de satélite para apoiar decisões de irrigação em agricultura de precisão, reduzindo desperdício de água e aumentando a eficiência produtiva?

Objetivo geral

Objetivo geral

Propor e desenvolver um sistema de agricultura de precisão focado no manejo hídrico sustentável, baseado na fusão de dados de sensores IoT e imagens de satélite, com o propósito de gerar mapas de recomendação de irrigação mais precisos e eficientes.

Objetivos específicos (1/2)

① Revisar a literatura e o estado da arte sobre:

- Tecnologias de IoT aplicadas à agricultura
- Sensoriamento remoto voltado ao manejo hídrico
- Técnicas de fusão de dados e aprendizado de máquina em agricultura de precisão

② Definir a arquitetura do sistema, especificando:

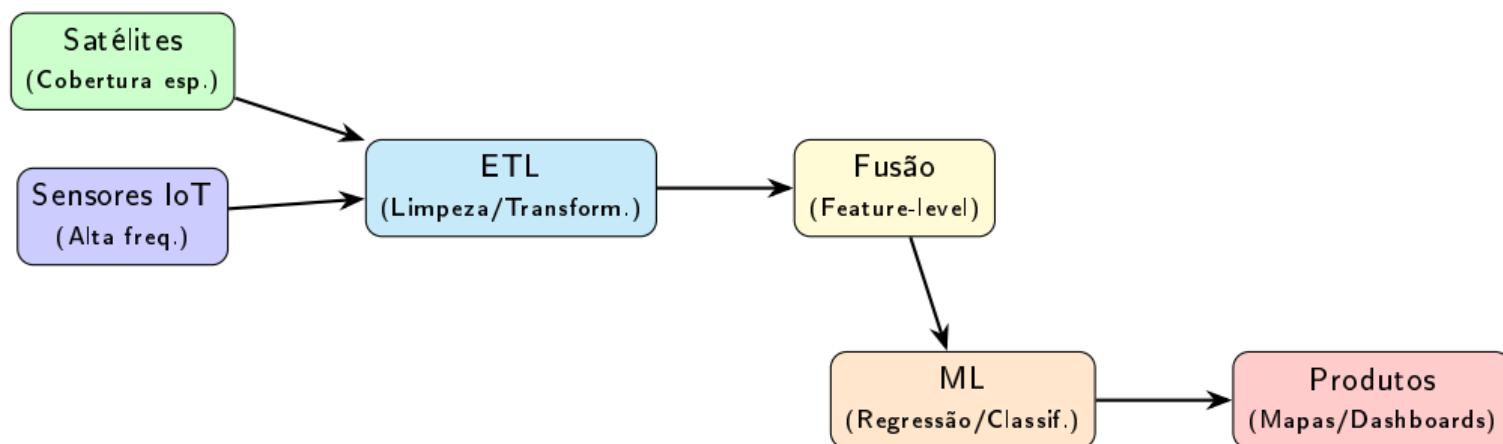
- Componentes de **hardware** para coleta de dados
- Plataforma de **software** para ingestão e armazenamento

③ Estabelecer a metodologia para aquisição e processamento de imagens orbitais

Objetivos específicos (2/2)

- ④ Desenvolver um modelo de *machine learning* para realizar a fusão dos dados, correlacionando medições pontuais e de alta frequência (IoT) com dados espaciais e de menor frequência (satélite)
- ⑤ Implementar um protótipo de sistema que utilize o modelo de fusão para gerar:
 - Mapas
 - Relatórios de irrigação
 - Dashboards de recomendação e alerta sobre a irrigação
- ⑥ Analisar a eficácia potencial do sistema na redução do desperdício de água e no aumento da eficiência produtiva

Solução proposta



Visão geral da abordagem

- Dois caminhos complementares de obtenção de dados:
 - **Caminho A — uso de *datasets* existentes**
 - **Caminho B — coleta em campo com rede própria baseada em LoRaWAN**
- Etapas principais:
 - ① Gate de decisão (**Caminho A vs. B**)
 - ② **Delineamento experimental**
 - ③ **Aquisição de dados (IoT + SR)**
 - ④ **Fusão espaço–temporal**
 - ⑤ **Modelagem e geração de produtos**
 - ⑥ **Validação e análise de desempenho**

Materiais: dados (Caminho A)

- Caminho A — Dataset existente

- **Séries históricas** e/ou **datasets** acadêmicos com **variáveis de solo/umidade** e apoio meteorológico [1][2][3]
(Bônus: uso de dados meteorológicos de estações locais próximas)
- Sensoriamento remoto: **Sentinel-2 (MSI)**, **Landsat-8/9 (OLI/TIRS)** e **Sentinel-1 (SAR)**
(Bônus: uso de dados vetoriais para auxílio no limite de talhão, rede de drenagem, solos e corpos d'água)

- Critérios de escolha:

- **Cobertura temporal e espacial**
- **Qualidade das variáveis disponíveis**

Materiais: coleta em campo (Caminho B)

- **Caminho B — Rede própria em 1–2 talhões**
 - Medições de **umidade do solo**
 - **Temperatura e umidade relativa do ar**
 - **Registros de validação manual** (checklist de campo; amostras pontuais)
- ***Hardware e comunicação:***
 - Microcontrolador **ESP32 com suporte a LoRa**
 - **Gateway LoRaWAN (TTN/ChirpStack) ou Raspberry Pi com módulo LoRa**
 - **Sensores capacitivos/tensiometréticos de umidade, sensores de T/UR do ar**

Materiais: *software* e organização dos dados

- **Software e serviços:**

- Ambiente Python (venv/conda)
- **Bibliotecas:** GDAL/rasterio, SNAP/Sen2Cor, **Google Earth Engine**
- **Telemetria:** The Things Stack/TTN, **MQTT/HTTP**, *scripts* de ingestão
- Ciência de dados e visualização: numpy, pandas, scikit-learn, QGIS, Dash/Streamlit

- **Organização e gestão de dados:**

- Estrutura de pastas: raw/, interim/, processed/, models/, reports/
- **Metadados** (CSV/Parquet): sensor, lat, lon, data/hora local, DOY, QA flags, CRS
- Controle de **versionamento**: **Git/GitHub**

(Bônus: o uso do *Data Version Control* (DVC) para grandes volumes de dados)

Gate de decisão e delineamento experimental

- **Gate de decisão (Mês 1–2):**
 - ① Verificar disponibilidade e suficiência de **datasets existentes**
 - ② Se suficientes: adotar Caminho A para acelerar modelagem
 - ③ Caso contrário: utilizar Caminho B com coleta em campo via LoRaWAN
- Delineamento experimental:
 - Definir cultura, talhões e variáveis de interesse
 - Planejar janelas de aquisição (solo, clima, SR)

Aquisição de dados e sensoriamento remoto

- Aquisição (IoT + meteorologia):
 - Leituras de sensores em alta frequência
 - Agregação em janelas de 15–60 minutos para modelagem
- Sensoriamento remoto (comum aos caminhos A e B):
 - Critérios: nuvem < X%, coleções L2A (Sentinel-2) / C2 (Landsat 8/9)
 - Óptico: correção atmosférica (Sen2Cor), máscara de nuvem/sombra, recorte ao talhão
 - SAR: calibração radiométrica, correção de terreno, co-registro S1↔S2
 - Derivação de índices: NDWI/MNDWI (água), NDVI/NDMI (vigor/umidade), LST/ET quando aplicável [4]

Fusão espaço-temporal, modelagem e produtos

- **Fusão espaço-temporal:**

- Alinhamento temporal/espacial
- Uso de *Harmonized Landsat Sentinel-2 (HLS)* e composições para **reduzir lacunas de nuvem**
- Níveis de fusão:
 - *Sensor-level*: reamostragem/**registro** ↔ pontos/**talhões**
 - *Feature-level*: *feature set* com **índices SR + agregados IoT + clima**

- **Modelagem e produtos:**

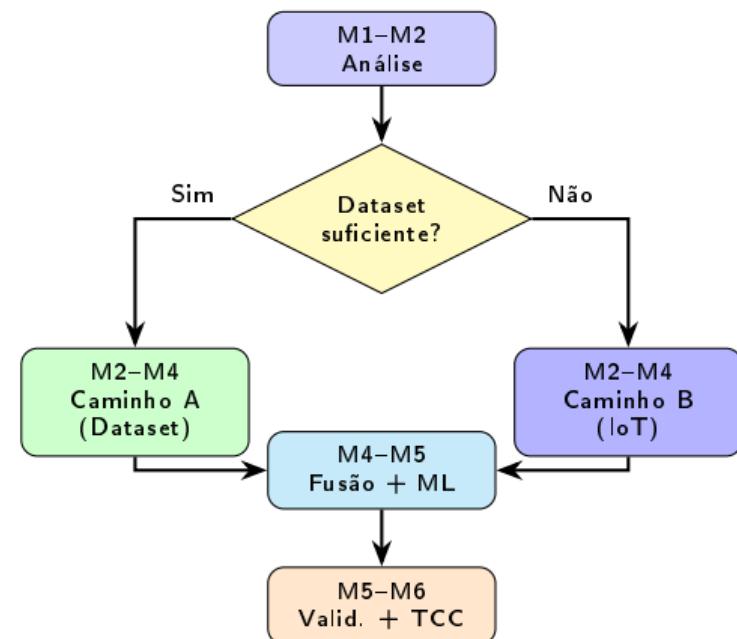
- **Baselines**: regressão (umidade/ET) e **classificação** (água/estresse)
- **Produtos**: **GeoTIFF/COG**, camadas temáticas, **mapas de recomendação de irrigação**, **dashboards** e **relatórios de alerta**

Validação

- Esquema espaço–temporal: treino/validação/teste por talhão/tempo
- Métricas: *Root Mean Square Error* (RMSE)/*Mean Absolute Error* (MAE) (variáveis contínuas), *F1-Score*/*Intersection over Union* (IoU) (segmentação água/estresse)
- Ganho operacional: economia potencial de água

Cronograma de atividades

Mês	Atividade
M1–M2	Gate de decisão (A vs. B) Instalação/calibração (se B)
M2–M4	Coleta IoT contínua (se B) Aquisição + pré-proc. SR
M4–M5	Fusão de dados Modelagem baseline
M5–M6	Validação e ajustes Geração de produtos Escrita Final do TCC



Situação atual do projeto

- Capítulos de **Introdução, Fundamentação Teórica e Desenvolvimento** já estruturados
- Etapas concluídas/adiantadas:
 - **Revisão bibliográfica** (IoT, SR, fusão de dados, ML)
 - **Definição de objetivos e arquitetura em camadas**
 - **Planejamento dos caminhos A e B**
 - **Estruturação do ambiente** de dados e da organização de pastas
- Principais aprendizados:
 - **Desafios de integração** de fontes **heterogêneas**
 - **Gestão e versionamento** de grandes volumes de dados
 - **Modelagem de aprendizado de máquina com dados espaço–temporais**

Resultados esperados e métricas

- Resultados esperados:

- **Dataset integrado** IoT + satélite em nível de talhão
- **Mapas de recomendação de irrigação** por período/safra
- **Protótipo de interface visual** com mapas, séries temporais e alertas

- Métricas de avaliação:

- **RMSE/MAE** para variáveis contínuas (umidade, ET, etc.)
- **F1/IoU** para classes de água/estresse, quando aplicável
- **Indicadores de gain operacional** (economia potencial de água)

Contribuições do trabalho

- Organização de **boas práticas de projeto de dados** para fusão IoT–satélite
- Proposição de **arquitetura em camadas** para manejo hídrico sustentável:
 - **Aquisição, transmissão, armazenamento e tratamento** de dados
- Documentação de **metodologia de fusão IoT–sensoriamento remoto**
- Base estruturada para desenvolvimentos futuros em:
 - **Irrigação inteligente**
 - **Agricultura de precisão sustentável**

Limitações e desafios

- Dependência da **qualidade e disponibilidade dos dados**:
 - Cobertura de nuvens em imagens orbitais
 - **Falhas de sensores** ou de **comunicação**
- Questões de **escalabilidade**:
 - **Generalização para diferentes culturas e regiões**
- Complexidade de operação:
 - Necessidade de **conhecimentos em geoprocessamento, programação e ciência e análise de dados**

Trabalhos futuros

- **Implantar e avaliar a rede IoT em área piloto (Caminho B)**
- **Explorar diferentes modelos de *machine learning* e comparar desempenho**
- **Incorporar novas fontes de dados:**
 - **Sensores adicionais** (tensiômetros, estações meteorológicas completas)
 - **Séries temporais mais longas** de satélite e dados climáticos
- **Evoluir a interface para um dashboard operacional** utilizável por técnicos e produtores
- **Realizar validação operacional** em parceria com produtores e instituições

Referências

-  Bhadra, M. (2024). Agriculture and Farming Dataset. Kaggle. www.kaggle.com/datasets/bhadramohit/agriculture-and-farming-dataset
-  Kaggle Community. (2023). Agricultural Datasets Discussion. Kaggle Discussions. www.kaggle.com/discussions/general/446746
-  DatasetEngineer. (2024). Smart Farming Data 2024 (SF24). Kaggle. www.kaggle.com/datasets/datasetengineer/smart-farming-data-2024-sf24
-  The IDB-Project. (2011). A database for remote sensing indices. www.indexdatabase.de/db/i.php

Agradecimentos e contato

Obrigado pela atenção!

Fernando Daniel Marcelino

fernando.marcelino@unifesp.br



Repositório do projeto:
github.com/fernando-daniel98/TCC-UNIFESP