



Fernando Daniel Marcelino

**Sistema de Agricultura de Precisão para o Manejo
Sustentável de Recursos Hídricos baseado na Fusão
de Dados de Sensores IoT e Imagens de Satélite**

São José dos Campos, SP

Fernando Daniel Marcelino

Sistema de Agricultura de Precisão para o Manejo Sustentável de Recursos Hídricos baseado na Fusão de Dados de Sensores IoT e Imagens de Satélite

Trabalho de conclusão de curso apresentado ao Instituto de Ciência e Tecnologia – UNIFESP, como parte das atividades para obtenção do título de Bacharel em Engenharia de Computação.

Universidade Federal de São Paulo – UNIFESP

Instituto de Ciência de Tecnologia

Bacharelado em Engenharia de Computação

Orientador: Profa. Dra. Fernanda Quelho Rossi

São José dos Campos, SP

Dezembro de 2025

Este trabalho é dedicado aos meus pais que sempre me apoiaram e me incentivaram.

Agradecimentos

Agradeço à minha família e em especial aos meus pais, Edmilson Aparecido Marcelino e Lucineia Domingues Marcelino, que dedicaram seus esforços para a minha educação.

Agradeço à minha orientadora, Profa. Dra. Fernanda Quelho Rossi, pelo apoio, paciência e ensinamentos ao longo deste trabalho. Não apenas durante a elaboração desta monografia, mas durante toda a minha trajetória acadêmica.

Agradeço também aos meus amigos e colegas de curso, que tornaram essa jornada mais leve e divertida. Levo cada momento compartilhado com vocês como aprendizado e crescimento pessoal.

Agradeço à Universidade Federal de São Paulo (UNIFESP) e ao Instituto de Ciência e Tecnologia (ICT) por me proporcionar todo amparo e estrutura necessária para a minha formação acadêmica.

Por fim, agradeço a todos que, de alguma forma, contribuíram para a realização deste trabalho.

*“A educação é a arma mais poderosa
que você pode usar para mudar o mundo.”*
(Nelson Mandela)

Resumo

A escassez e a distribuição desigual dos recursos hídricos colocam a agricultura sob forte pressão para produzir mais, com menor desperdício de água e menor impacto ambiental. Diante desse cenário, e em consonância com os Objetivos de Desenvolvimento Sustentável (ODS 2, 6 e 12), esta monografia descreve o projeto de um sistema de agricultura de precisão para o manejo sustentável de recursos hídricos, fundamentado na integração de duas fontes principais de informação: medições de redes de sensores em campo e dados de sensoriamento remoto orbitais. O trabalho aborda, inicialmente, os fundamentos teóricos de Internet das Coisas (IoT), sensoriamento remoto e fusão de dados, com ênfase em sensores de umidade do solo, índices espectrais derivados de imagens multiespectrais e produtos de missões espaciais como Sentinel e Landsat. Em seguida, é proposta uma arquitetura em camadas que abrange aquisição, transmissão, armazenamento e tratamento de dados, incluindo rotinas de pré-processamento e sincronização temporal. A partir desse fluxo, são definidos conjuntos de atributos que combinam variáveis de solo, clima e informações espectrais para alimentar modelos de aprendizado de máquina voltados à estimativa de indicadores de estado hídrico e à geração de mapas de recomendação de irrigação em nível de talhão. Complementarmente, delineia-se a implementação de um protótipo de interface visual para apoio à decisão, capaz de apresentar mapas, séries temporais e alertas de forma intuitiva. Como contribuição, o trabalho organiza boas práticas de projeto de dados, documenta uma metodologia de fusão IoT–satélite e oferece uma base estruturada para desenvolvimentos futuros em irrigação inteligente e agricultura de precisão sustentável.

Palavras-chave: agricultura de precisão; recursos hídricos; irrigação inteligente; Internet das Coisas; sensoriamento remoto.

Abstract

Water scarcity and the uneven distribution of water resources place agriculture under strong pressure to increase production while reducing water waste and environmental impacts. In this context, and in accordance with the Sustainable Development Goals (SDGs 2, 6 and 12), this monograph describes the design of a precision agriculture system for sustainable water resources management, grounded in the integration of two main sources of information: measurements from in-field IoT sensor networks and orbital remote sensing data. The work first discusses the theoretical foundations of the Internet of Things, remote sensing and data fusion, with textitatis on soil moisture sensors, spectral indices derived from multispectral imagery and products from space missions such as Sentinel and Landsat. Next, a layered architecture is proposed, covering data acquisition, transmission, storage and processing, including preprocessing routines and temporal synchronization. Based on this flow, feature sets are defined that combine soil, climate and spectral variables to feed machine learning models aimed at estimating indicators of crop water status and generating irrigation recommendation maps at field level. Additionally, the implementation of a visual decision-support prototype is outlined, capable of presenting maps, time series and alerts in an intuitive way. As its main contributions, this work organizes data-project best practices, documents a methodology for IoT–satellite data fusion and provides a structured basis for future developments in smart irrigation and sustainable precision agriculture.

Key-words: precision agriculture; water resources; smart irrigation; Internet of Things; remote sensing.

Lista de ilustrações

Figura 1 – Arquitetura de alto nível para rede IoT.	29
Figura 2 – Diagrama de blocos funcional do SoC ESP32.	31
Figura 3 – Layout de pinos do encapsulamento do ESP32.	32
Figura 4 – Processo físico de formação da imagem de sensoriamento remoto pela fonte solar.	33

Lista de tabelas

Tabela 1 – Cronograma das atividades do Trabalho de Conclusão de Curso (TCC). . . . 40

Lista de abreviaturas e siglas

ABNT	Associação Brasileira de Normas Técnicas
ADC	Conversor Analógico–Digital (<i>Analog-to-Digital Converter</i>)
ALOS	<i>Advanced Land Observing Satellite</i>
API	Interface de Programação de Aplicações (<i>Application Programming Interface</i>)
ASTER	<i>Advanced Spaceborne Thermal Emission and Reflection Radiometer</i>
CLI	Interface de Linha de Comando (<i>Command-Line Interface</i>)
COG	<i>Cloud Optimized GeoTIFF</i> (GeoTIFF otimizado para acesso em nuvem)
CPU	Unidade Central de Processamento (<i>Central Processing Unit</i>)
CRS	Sistema de Referência de Coordenadas (<i>Coordinate Reference System</i>)
CSS	<i>Chirp Spread Spectrum</i> (Espalhamento espectral por chirp)
CSV	Valores Separados por Vírgula (<i>Comma-Separated Values</i>)
DOY	Dia do Ano (<i>Day of Year</i>)
DVC	<i>Data Version Control</i> (controle de versão de dados)
EM38-MK2	Sensor de indução eletromagnética Geonics EM38-MK2
ESP	Família de microcontroladores da Espressif
ESP32	Microcontrolador/SoC da Espressif (família ESP)
ET	Evapotranspiração
F1	Medida-F1 (<i>F1-score</i>)
GDAL	<i>Geospatial Data Abstraction Library</i>
GeoTIFF	<i>Geographic Tagged Image File Format</i>
GPIO	Entradas/Saídas de Propósito Geral (<i>General Purpose Input/Output</i>)
GPS	Sistema de Posicionamento Global (<i>Global Positioning System</i>)
Git	Sistema de controle de versão distribuído (<i>Git</i>)

GitHub	Plataforma de hospedagem e colaboração de repositórios Git
HLS	<i>Harmonized Landsat and Sentinel-2</i>
HTTP	<i>Hypertext Transfer Protocol</i>
I2C	<i>Inter-Integrated Circuit</i>
IDE	<i>Integrated Development Environment</i> (Ambiente de Desenvolvimento Integrado)
INMET	Instituto Nacional de Meteorologia
IoT	Internet das Coisas (<i>Internet of Things</i>)
IoU	Interseção sobre União (<i>Intersection over Union</i>)
LPWAN	<i>Low-Power Wide-Area Network</i>
LoRa	<i>Long Range</i>
LoRaWAN	<i>LoRa Wide Area Network</i>
LST	Temperatura da Superfície Terrestre (<i>Land Surface Temperature</i>)
LX6	Núcleo Xtensa LX6 (microarquitetura usada no ESP32)
MAE	Erro Absoluto Médio (<i>Mean Absolute Error</i>)
MCU	Unidade de Microcontrolador (<i>Microcontroller Unit</i>)
ML	Aprendizado de Máquina (<i>Machine Learning</i>)
MNDWI	<i>Modified Normalized Difference Water Index</i>
MQTT	<i>Message Queuing Telemetry Transport</i>
MSI	<i>MultiSpectral Instrument</i> (Sentinel-2)
MySQL	Sistema Gerenciador de Banco de Dados relacional MySQL
NDMI	<i>Normalized Difference Moisture Index</i>
NDVI	<i>Normalized Difference Vegetation Index</i>
NDWI	<i>Normalized Difference Water Index</i>
NIR	Infravermelho Próximo (<i>Near-Infrared</i>)
ODS	Objetivos de Desenvolvimento Sustentável

OLI/TIRS	<i>Operational Land Imager/Thermal Infrared Sensor</i> (Landsat 8/9)
ONU	Organização das Nações Unidas
PALSAR	<i>Phased Array type L-band Synthetic Aperture Radar</i>
PCA	Análise de Componentes Principais (<i>Principal Component Analysis</i>)
QA/QC	Garantia/Controle de Qualidade (<i>Quality Assurance/Quality Control</i>)
QGIS	<i>Quantum GIS</i> (software SIG de código aberto)
RF	Rádio Frequência
RMSE	Raiz do Erro Quadrático Médio (<i>Root Mean Square Error</i>)
RTC	Relógio de Tempo Real (<i>Real-Time Clock</i>)
S1	Sentinel-1
S2	Sentinel-2
SAR	Radar de Abertura Sintética (<i>Synthetic Aperture Radar</i>)
SDA/SCL	Linhas de dados/clock do barramento I2C (<i>Serial Data/Serial Clock</i>)
SIMEPAR	Sistema de Tecnologia e Monitoramento Ambiental do Paraná
SMA	Sistema Multiagente
SNAP	<i>Sentinel Application Platform</i>
SoC	Sistema em Chip (<i>System-on-Chip</i>)
SPI	<i>Serial Peripheral Interface</i>
SR	Sensoriamento Remoto
SRAM	Memória RAM Estática (<i>Static Random-Access Memory</i>)
SWIR	Infravermelho de Ondas Curtas (<i>Shortwave Infrared</i>)
TCC	Trabalho de Conclusão de Curso
TTN	<i>The Things Network</i>
UART	<i>Universal Asynchronous Receiver-Transmitter</i>
ULA	Unidade Lógica e Aritmética
UNIFESP	Universidade Federal de São Paulo

UR	Umidade Relativa
UTM	<i>Universal Transverse Mercator</i>
Wi-Fi	Rede local sem fio (<i>Wireless Fidelity</i>)
ZigBee	Protocolo de comunicação sem fio de baixo consumo (<i>ZigBee</i>)

Sumário

1	Introdução	21
1.1	Trabalhos Correlatos	22
1.1.1	IoT na agricultura: de revisões gerais a aplicações em campo	22
1.1.2	Sensoriamento remoto e gestão hídrica na agricultura	23
1.1.3	Fusão de sensores próximos e remotos no manejo da irrigação	24
1.1.4	Síntese crítica e relação com o trabalho proposto	25
1.2	Definição do Problema	25
1.3	Objetivos	26
1.3.1	Objetivo Geral	26
1.3.2	Objetivos Específicos	26
1.4	Estrutura do Texto	27
2	Fundamentação Teórica	29
2.1	Internet das Coisas e Protocolos de Comunicação	29
2.1.1	Redes LPWAN e Protocolo LoRaWAN	30
2.2	Hardware e Sistemas Embarcados	30
2.2.1	Microcontroladores (MCUs) e o SoC ESP32	30
2.2.2	Princípios de Transdução e Sensores	31
2.2.3	Interfaces de Comunicação Periférica	32
2.3	Sensoriamento Remoto (SR)	32
2.3.1	Processo Físico de Formação da Imagem	33
2.3.2	Índices Espectrais de Vegetação e Água	33
2.3.2.1	NDVI (<i>Normalized Difference Vegetation Index</i>)	34
2.3.2.2	NDWI (<i>Normalized Difference Water Index</i>)	34
2.4	Aprendizado de Máquina (<i>Machine Learning</i>)	34
2.4.1	Tipos de Aprendizado	34
2.4.2	Tarefas e Fusão de Dados	35
3	Desenvolvimento	37
3.1	Materiais	37
3.1.1	Dados	37
3.1.2	<i>Hardware</i> e comunicação (Caminho B)	37
3.1.3	<i>Software</i> e serviços	38
3.1.4	Organização e gestão de dados	38
3.2	Métodos	38
3.2.1	<i>Gate</i> de decisão (Mês 1–2)	38

3.2.2	Delineamento experimental	38
3.2.3	Aquisição de dados	39
3.2.4	Sensoriamento remoto (comum aos caminhos A e B)	39
3.2.5	Fusão espaço-temporal	39
3.2.6	Modelagem e produtos	40
3.2.7	Validação	40
3.2.8	Reprodutibilidade e ética	40
3.3	Cronograma de atividades	40
4	Resultados e Discussão	41
5	Conclusão	43
Referências	45

1 Introdução

Nas últimas décadas, o aumento da demanda global por alimentos e a intensificação da agricultura têm elevado a pressão sobre os recursos naturais, especialmente a água. Esse recurso, essencial para a manutenção da vida e para a produção agrícola, vem sofrendo escassez em diversas regiões, o que tem intensificado a busca por soluções que promovam o uso racional e sustentável da água ([FAO, 2022](#)). Essa preocupação está diretamente alinhada aos Objetivos de Desenvolvimento Sustentável (ODS), estabelecidos pela Agenda 2030 da Organização das Nações Unidas (ONU), em especial os ODS de números 2, 6 e 12, que visam assegurar a segurança alimentar, melhorar o manejo hídrico e promover práticas agrícolas sustentáveis. Nesse contexto, a gestão eficaz e sustentável da água na agricultura não é apenas uma necessidade técnica, mas uma demanda decisiva para garantir a estabilidade ambiental e social ([ROCHA; GUIMARÃES; OLIVEIRA, 2024](#)).

Ao mesmo tempo, o avanço das tecnologias digitais aplicadas à agricultura, como o sensoriamento remoto e a IoT, tem possibilitado a coleta massiva de dados ambientais e produtivos, abrindo novas oportunidades para o aprimoramento do manejo hídrico e o aumento da eficiência no uso da água. Entretanto, observa-se que a adoção dessas tecnologias ainda ocorre de forma fragmentada, impedindo uma visão integrada e em tempo quase real da dinâmica hídrica nas lavouras. Segundo [Wang et al. \(2024\)](#), apesar do progresso obtido pela combinação de sensores de solo, dados de satélite e técnicas de aprendizado de máquina, persistem desafios relacionados à qualidade, à padronização e à interoperabilidade das informações — fatores que comprometem a construção de modelos generalizáveis para a agricultura de precisão. Essa falta de integração entre diferentes fontes de dados limita a geração de produtos aplicáveis, como mapas de irrigação e relatórios de recomendação, que são essenciais para orientar práticas agrícolas mais eficientes e ambientalmente responsáveis.

Diante desse cenário, o presente estudo propõe o desenvolvimento de uma metodologia de fusão de dados que combine informações provenientes de sensores IoT e de imagens de satélite, utilizando técnicas de aprendizado de máquina para gerar recomendações precisas e dinâmicas de irrigação. Essa abordagem busca superar as lacunas existentes na integração e automação de dados agrícolas, promovendo uma visão mais completa e multiescalar do comportamento hídrico das áreas cultivadas. Ao conectar o desafio global da sustentabilidade hídrica às oportunidades proporcionadas pela inovação tecnológica, esta pesquisa se apresenta como uma contribuição concreta à agricultura de precisão sustentável, fortalecendo o compromisso com o uso racional dos recursos naturais e com os objetivos propostos pela Agenda 2030.

1.1 Trabalhos Correlatos

Após a contextualização apresentada, que evidencia a pressão crescente sobre os recursos hídricos e o alinhamento do tema aos Objetivos de Desenvolvimento Sustentável (ODS 2, 6 e 12), e de toda fundamentação teórica, que definiu os conceitos de IoT e sensoriamento remoto aplicados ao manejo hídrico, esta seção discute trabalhos que efetivamente aplicam essas tecnologias em contextos agrícolas.

Os estudos selecionados foram organizados em três eixos: (i) IoT na agricultura, desde revisões gerais até aplicações em campo; (ii) sensoriamento remoto e gestão hídrica; e (iii) fusão de sensores próximos e remotos. Em conjunto, esses trabalhos ajudam a explicitar a lacuna que esta monografia busca abordar: a integração sistemática entre dados de redes de sensores IoT e produtos de sensoriamento remoto para apoiar decisões de irrigação em agricultura de precisão.

1.1.1 IoT na agricultura: de revisões gerais a aplicações em campo

Em consonância com a discussão sobre o papel da IoT na agricultura 4.0, [Kumar et al. \(2024\)](#) apresentam uma revisão extensa sobre o uso de tecnologias de IoT na agricultura inteligente e sustentável. Os autores descrevem arquiteturas em camadas (sensoriamento, comunicação e aplicação), tipos de sensores (solo, clima, planta), protocolos de comunicação (Wi-Fi, LoRa, ZigBee, entre outros) e plataformas em nuvem para armazenamento e análise de dados. O survey também destaca aplicações como irrigação inteligente, monitoramento de condições ambientais, rastreabilidade e automação de operações agrícolas, associando-as a ganhos em eficiência de uso de insumos, produtividade e sustentabilidade. Ao mesmo tempo, aponta desafios recorrentes, como limitações de conectividade em áreas rurais, interoperabilidade entre dispositivos heterogêneos, segurança, privacidade e modelos de negócio para adoção em larga escala.

Focando especificamente em sistemas pecuários, mas com pertinência técnica ao contexto agrícola em geral, [Farooq et al. \(2022\)](#) realizam um survey sobre o papel da IoT na implementação de ambientes de pecuária inteligente. O trabalho discute de forma detalhada a infraestrutura de redes IoT, arquiteturas em camadas, topologias e protocolos de comunicação, bem como desafios de escalabilidade, consumo energético, robustez da comunicação sem fio e padronização. São apresentados casos de uso envolvendo sensores vestíveis, coleiras inteligentes e nós distribuídos para monitoramento de saúde, bem-estar e produtividade dos animais. Embora o foco seja a produção animal, os pontos críticos levantados – sobretudo no que se refere à confiabilidade da rede e à gestão de grandes volumes de dados – são análogos aos enfrentados por redes de sensores de solo e clima, reforçando aspectos sobre os limites e potencialidades da IoT em ambientes rurais.

No contexto da agricultura familiar brasileira, [Gomes, Innocentini e Formigoni \(2023\)](#) propõem uma solução de baixo custo baseada em IoT para monitoramento agroclimático e su-

porte à irrigação sustentável, aproximando os conceitos discutidos na revisão de Kumar et al. (2024) de uma realidade de pequena escala, fundamental para o presente estudo. O sistema integra sensores de umidade e temperatura do ar e do solo, sensores de vazão e atuadores de irrigação a um software supervisório de código aberto (ScadaBR), com armazenamento dos dados em banco MySQL. Implantada em horta experimental no Sul/Sudoeste de Minas Gerais, a solução apresenta boa concordância entre os dados coletados e informações meteorológicas oficiais do INMET, evidenciando potencial para apoiar decisões de irrigação e reduzir desperdícios de água em propriedades com restrições de capital. Este estudo reforça, de forma prática, a viabilidade de arquiteturas acessíveis e abertas para o contexto de agricultura familiar e para estudo em pequeno porte.

Trinta, Cesar e Pantoja (2021) avançam na direção da automatização da irrigação, ao apresentar um sistema autônomo de gerenciamento baseado em uma arquitetura com Sistema Multiagente (SMA) e IoT. Na solução proposta, um Raspberry Pi executa os agentes responsáveis por tomar decisões a partir de dados coletados por microcontroladores, que leem sensores de solo e clima e acionam atuadores de irrigação. A comunicação ocorre via *middleware* ContextNet, e uma aplicação web permite ao usuário acompanhar o estado do cultivo e intervir quando necessário. Os resultados do estudo de caso indicam que a abordagem com SMA aumenta a autonomia do sistema, possibilitando decisões de irrigação mesmo na ausência de intervenção humana direta e reduzindo a dependência de monitoramento manual. Ao trazer a inteligência para a borda da rede, o trabalho se aproxima da proposta desta monografia de utilizar dados de sensores de campo como insumo para decisões automatizadas de manejo hídrico, porém ainda sem integrar explicitamente informações orbitais.

1.1.2 Sensoriamento remoto e gestão hídrica na agricultura

Do ponto de vista da gestão hídrica em escala de sistema produtivo, Rocha, Guimarães e Oliveira (2024) realizam uma revisão sobre técnicas de irrigação e tecnologias voltadas à minimização do desperdício de água na agricultura, retomando a problemática de escassez de recursos. O artigo examina alguns métodos de irrigação (como gotejamento, aspersão e sistemas localizados), além de tecnologias de monitoramento que incluem desde sensores de solo, estações meteorológicas até ferramentas de apoio às decisões. Os autores discutem ganhos em economia de água, energia e fertilizantes, mas ressaltam barreiras relacionadas a custos de implantação, necessidade de capacitação técnica e desigualdade de acesso entre os produtores. Ao defenderem uma abordagem integrada que considere simultaneamente dimensões técnicas, econômicas, sociais e ambientais, reforçam a importância de arranjos tecnológicos como o proposto nesta monografia, que articula IoT e sensoriamento remoto.

Muturi, Ndehedehe e Kennard (2025) acrescentam a perspectiva do sensoriamento remoto, ao revisarem o uso de técnicas orbitais para estimar o uso de água na irrigação. O estudo mapeia abordagens baseadas em evapotranspiração, umidade do solo, balanço hídrico e fusão de

dados de múltiplos sensores, contemplando diferentes escalas espaciais. São discutidos o papel de sensores ópticos, térmicos e de micro-ondas, bem como a importância de séries temporais e de dados de campo para calibração e validação. Entre as lacunas apontadas estão a subexploração de sensores de micro-ondas, a escassez de séries longas e de estudos comparativos, além da necessidade de quantificar incertezas quando essas estimativas subsidiam políticas de alocação de água. Essas observações reforçam a relevância de integrar medições locais, como as fornecidas por redes IoT, às estimativas derivadas de imagens de satélite.

[Wang et al. \(2024\)](#) ampliam esse panorama ao discutir a integração entre sensoriamento remoto e algoritmos de aprendizado de máquina na agricultura de precisão, retomando a ênfase no uso de técnicas de inteligência computacional. Os autores sistematizam aplicações que combinam imagens de satélite, sensores hiperespectrais, plataformas aéreas não tripuladas e sensores de proximidade com modelos como máquinas de vetor de suporte, florestas aleatórias e redes neurais profundas. São apresentados exemplos em estimativa de produtividade, detecção de estresse hídrico, mapeamento de atributos de solo e delimitação de zonas de manejo. Ao mesmo tempo, o estudo enfatiza desafios de qualidade e padronização dos dados, interpretabilidade dos modelos e transferência entre regiões com diferentes condições de solo e de clima. Esses pontos se alinham com as limitações de generalização e importância do contexto local, reforçando a necessidade de abordagens de fusão que aproveitem dados orbitais e de campo de forma complementar.

1.1.3 Fusão de sensores próximos e remotos no manejo da irrigação

[Rodrigues et al. \(2024\)](#) aproximam-se de forma direta da proposta desta monografia ao explorar a fusão de dados de sensores proximais e remotos para apoio ao zoneamento de manejo de irrigação, articulada ao conceito de “gêmeos digitais”. Em um pivô central de 72 ha no estado de São Paulo, os autores coletam dados de condutividade elétrica aparente do solo com sensor proximal EM38-MK2 em alta densidade e, em seguida, simulam um cenário de amostragem esparsa com menos linhas de coleta, representando uma situação de menor custo operacional. Esses dados são combinados com covariáveis derivadas de modelos digitais de elevação e de imagens dos satélites *Advanced Land Observing Satellite* (ALOS) PALSAR, *Advanced Spaceborne Thermal Emission and Reflection Radiometer* (ASTER), Sentinel-2 e Landsat 8. Comparando diferentes métodos geoestatísticos e de regressão espacial, o estudo evidencia que a krigagem com deriva externa, alimentada pelas covariáveis de sensoriamento remoto, permite aproximar a acurácia do mapa de referência obtido com amostragem densa, tornando possível definir zonas de manejo de irrigação com menor esforço de campo.

Ainda que não utilizem explicitamente redes IoT, os trabalhos de [Muturi, Ndehedehe e Kennard \(2025\)](#), [Wang et al. \(2024\)](#) e [Rodrigues et al. \(2024\)](#) convergem com a Fundamentação Teórica ao demonstrar que o sensoriamento remoto, combinado a medições locais, é capaz de gerar produtos espaciais – como mapas de uso de água, zonas de manejo e indicadores de

estresse hídrico – altamente relevantes para decisões de irrigação. O ponto de tensão que emerge desses estudos, e que se conecta diretamente à lacuna identificada na literatura, é a ausência de arquiteturas bem descritas que integrem de ponta a ponta séries temporais de sensores e informações orbitais em fluxos operacionais de apoio à decisão.

1.1.4 Síntese crítica e relação com o trabalho proposto

Os trabalhos analisados confirmam o panorama delineado: soluções baseadas em IoT evoluíram significativamente rumo ao monitoramento em tempo quase real e à automação da irrigação em nível de propriedade, seja por meio de arquiteturas de baixo custo voltadas à agricultura familiar (GOMES; INNOCENTINI; FORMIGONI, 2023), seja via sistemas com inteligência distribuída, como os baseados em sistemas multiagentes (TRINTA; CESAR; PANTOJA, 2021). Em paralelo, a literatura em sensoriamento remoto e aprendizado de máquina consolidou métodos para estimar evapotranspiração, umidade do solo e uso de água na irrigação, além de delinear zonas de manejo com base em dados orbitais e proximais (ROCHA; GUIMARÃES; OLIVEIRA, 2024; MUTURI; NDEHEDEHE; KENNARD, 2025; WANG et al., 2024; RODRIGUES et al., 2024).

No entanto, a maior parte desses estudos permanece concentrada em um desses eixos de forma isolada: ora enfatizam a infraestrutura de IoT e a lógica de decisão local, ora exploram o potencial do sensoriamento remoto e de modelos preditivos, sem detalhar metodologias de fusão que conciliem a alta frequência temporal dos sensores de campo com a cobertura espacial e multiespectral das imagens de satélite. Assim, embora haja indicações claras do benefício de combinar essas fontes de dados – tanto nas revisões quanto nos estudos aplicados – ainda são relativamente raras as propostas que implementam, validam e documentam arquiteturas completas de integração entre IoT e sensoriamento remoto para apoio operacional à gestão hídrica em escala de talhão.

Diante desse panorama, reafirma-se o espaço de contribuição desta monografia: desenvolver e avaliar um método de fusão de dados entre redes de sensores IoT e produtos de sensoriamento remoto, apoiado em técnicas de aprendizado de máquina, voltado à otimização da gestão hídrica na agricultura de precisão. Ao articular os elementos discutidos na Introdução, na Fundamentação Teórica e nos Trabalhos Correlatos, o estudo busca oferecer uma abordagem integrada que contribua para o uso mais eficiente e sustentável da água, em apoio às diretrizes dos ODS e aos desafios práticos enfrentados em sistemas agrícolas reais.

1.2 Definição do Problema

A agricultura é um dos setores que mais demandam água e, ao mesmo tempo, um dos mais sensíveis à sua disponibilidade e à variabilidade espacial e temporal no campo. Na prática, ainda é comum que decisões de irrigação sejam tomadas com base em cronogramas fixos, ob-

servação empírica ou medições pontuais, o que pode levar tanto ao desperdício de água quanto ao estresse hídrico das culturas. Em um cenário de crescente pressão sobre os recursos naturais, essa lacuna dificulta a adoção de estratégias de manejo mais racionais e sustentáveis, alinhadas às demandas de eficiência e aos ODS relacionados a produção agrícola e gestão hídrica.

Embora tecnologias como sensores IoT e imagens de satélite permitam observar o sistema agrícola em diferentes escalas, sua adoção frequentemente ocorre de forma fragmentada, com dados heterogêneos, diferentes resoluções e dificuldades de interoperabilidade e sincronização temporal. Como consequência, torna-se desafiador transformar medições em campo e produtos de sensoriamento remoto em informações integradas e açãoáveis, como mapas e recomendações dinâmicas para o manejo hídrico. Assim, o problema central abordado neste trabalho é a ausência de uma metodologia e de uma arquitetura integradas que permitam fundir, padronizar e explorar essas fontes de dados de maneira consistente, viabilizando produtos aplicáveis para a agricultura de precisão.

1.3 Objetivos

Esta seção apresenta os objetivos que orientam o desenvolvimento do trabalho. O objetivo geral sintetiza a principal contribuição esperada com a proposta, enquanto os objetivos específicos detalham as etapas e entregáveis necessários para alcançá-la, incluindo a definição de requisitos, a arquitetura do sistema, o tratamento e a fusão das fontes de dados e a avaliação dos produtos gerados.

1.3.1 Objetivo Geral

O objetivo geral deste trabalho é propor e desenvolver um sistema de agricultura de precisão focado no manejo hídrico sustentável, baseado na fusão de dados de sensores IoT e imagens de satélite, visando gerar mapas de recomendação de irrigação mais precisos e eficientes.

1.3.2 Objetivos Específicos

Para atingir o objetivo geral proposto, estabelecem-se os seguintes objetivos específicos:

- Revisar a literatura e o estado da arte sobre as tecnologias de IoT, sensoriamento remoto e técnicas de fusão de dados aplicadas à agricultura de precisão;
- Definir a arquitetura do sistema, especificando os componentes de hardware para a coleta de dados e a plataforma de software para ingestão e armazenamento dos dados;
- Definir e estabelecer a metodologia para a aquisição e o processamento de imagens de satélite para a área de estudo;

- Desenvolver um modelo de *machine learning* para realizar a fusão dos dados, correlacionando as medições pontuais e de alta frequência dos sensores IoT com os dados espaciais de baixa frequência das imagens de satélite;
- Implementar um protótipo do sistema que utilize o modelo de fusão para gerar mapas, relatórios ou *dashboards* de recomendação e alerta sobre a irrigação, indicando a variabilidade da necessidade de irrigamento;
- Analisar a eficácia potencial do sistema proposto na redução do desperdício de água e no aumento da eficiência produtiva, validando a metodologia adotada.

1.4 Estrutura do Texto

Este trabalho está organizado em cinco capítulos, de modo a conduzir o leitor desde a contextualização do problema até a proposição da solução e a análise dos resultados. No Capítulo 1, apresentam-se a motivação e o contexto relacionados ao manejo sustentável de recursos hídricos na agricultura, bem como a definição do problema, os objetivos do estudo e a síntese de trabalhos correlatos que fundamentam a proposta.

Os capítulos subsequentes são estruturados da seguinte forma:

- O Capítulo 2 reúne os principais conceitos necessários para o desenvolvimento do trabalho, abrangendo Internet das Coisas e protocolos de comunicação aplicados ao monitoramento em campo, aspectos de *hardware* e sistemas embarcados, fundamentos de sensoriamento remoto e índices espectrais, além de noções de aprendizado de máquina e estratégias de integração/fusão de dados.
- O Capítulo 3 descreve os materiais e métodos empregados, contemplando as fontes de dados (uso de *datasets* e coleta em campo com rede baseada em LoRaWAN), a arquitetura proposta do sistema e o fluxo de aquisição, transmissão, armazenamento e pré-processamento, incluindo procedimentos de sincronização temporal e definição de atributos para análise.
- O Capítulo 4 apresenta os resultados obtidos e a respectiva discussão, analisando o comportamento do sistema e do pipeline de dados, bem como suas limitações e implicações para o manejo hídrico em agricultura de precisão.
- Por fim, o Capítulo 5 consolida as conclusões do estudo, relacionando-as aos objetivos propostos, e indica perspectivas de trabalhos futuros, como a ampliação da validação em campo, a incorporação de novos sensores/produtos orbitais e o aprimoramento das estratégias de fusão de dados.

2 Fundamentação Teórica

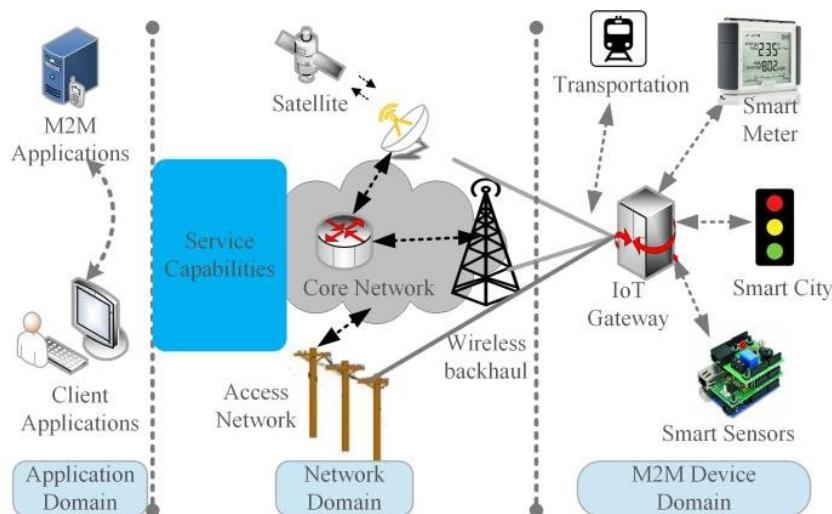
Este capítulo estabelece os pilares técnicos do projeto, detalhando a infraestrutura de comunicação e *hardware* (IoT), os princípios físicos do sensoriamento remoto e os métodos computacionais de aprendizado de máquina utilizados para a fusão de dados.

2.1 Internet das Coisas e Protocolos de Comunicação

A IoT é uma subárea da computação que se dedica à interconexão de dispositivos físicos à Internet, permitindo a coleta e troca de dados em tempo real. Seu funcionamento é pautado na integração de sensores, protocolos de comunicação e plataformas de processamento, e os produtos gerados dessa interação são fundamentais para a diversas áreas modernas, como cidades inteligentes, saúde conectada e agricultura de precisão ([MASCHIETTO et al., 2021](#)).

Quanto à agricultura de precisão, IoT transcende a simples conectividade de dispositivos, exigindo uma compreensão detalhada de arquiteturas distribuídas e restrições de energia. Segundo [Kumar et al. \(2024\)](#), uma solução de IoT robusta deve ser estruturada em camadas funcionais bem definidas: percepção (sensores), rede (transporte) e aplicação (processamento). Um esquemático de uma rede IoT em alto nível é apresentado na Figura 1.

Figura 1 – Arquitetura de alto nível para rede IoT.



Fonte: ([HAKIRI et al., 2015](#)).

A Figura 1 ilustra a estrutura típica de uma rede IoT, composta por três camadas principais: camada de domínio do dispositivo (sensores e atuadores), camada de rede (transporte de dados) e camada de aplicação (processamento e análise). Cada camada desempenha um papel

crucial na coleta, transmissão e utilização dos dados, e a escolha dos componentes e protocolos adequados é fundamental para o sucesso do sistema ([HAKIRI et al., 2015](#)).

2.1.1 Redes LPWAN e Protocolo LoRaWAN

Para o transporte de dados em cenários agrícolas, onde a infraestrutura celular é frequentemente precária, utilizam-se redes LPWAN (*Low-Power Wide-Area Networks*). Diferente de redes locais (Wi-Fi, ZigBee), as LPWAN priorizam o alcance estendido (quilômetros) e a eficiência energética em detrimento da alta taxa de transferência.

Neste trabalho, adota-se a tecnologia **LoRa** (*Long Range*) na camada física. A robustez do LoRa advém de sua modulação baseada em *Chirp Spread Spectrum* (CSS), que permite a decodificação de sinais mesmo abaixo do nível de ruído ([FAROOQ; AKRAM, 2021](#)). Sobre ela, opera o protocolo LoRaWAN (camada MAC), que define uma topologia em estrela onde os nós sensores comunicam-se diretamente com *gateways* centrais, otimizando o ciclo de vida das baterias.

2.2 Hardware e Sistemas Embarcados

A implementação de nós sensores em campo exige a compreensão da arquitetura de sistemas embarcados, que difere da computação de propósito geral por restrições severas de energia, memória e tempo de resposta.

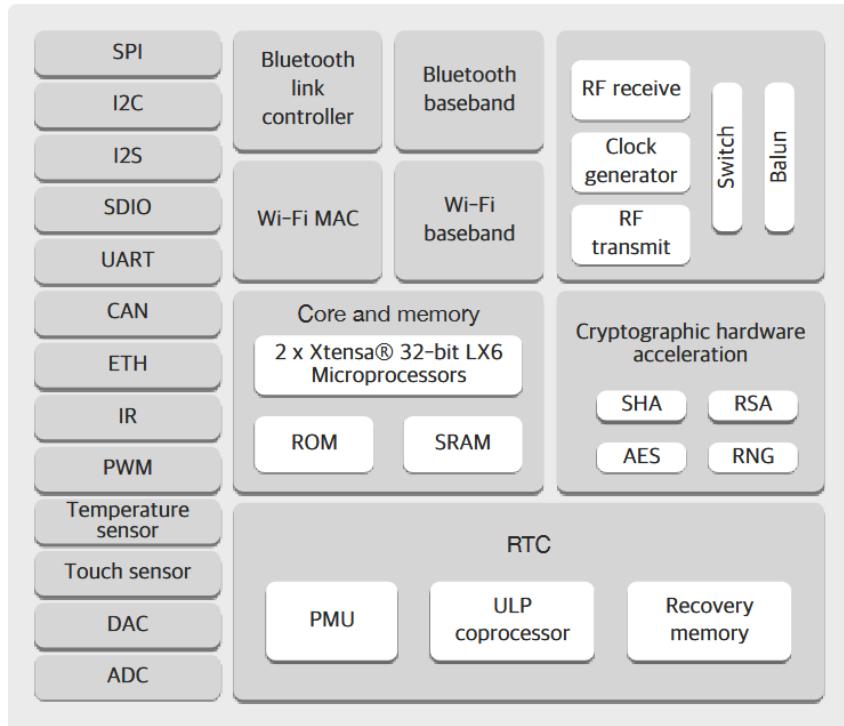
2.2.1 Microcontroladores (MCUs) e o SoC ESP32

Diferente dos microprocessadores convencionais, que dependem de barramentos externos para acessar memória e periféricos, os microcontroladores (*Microcontroller Units* - MCUs) são dispositivos altamente integrados (*System on Chip* - SoC). Um MCU típico encapsula em uma única pastilha de silício a Unidade Central de Processamento (CPU), memória não-volátil (Flash) para armazenamento do *firmware*, memória volátil (SRAM) para dados e interfaces de Entrada/Saída (GPIO) ([MASCHIETTO et al., 2021](#)).

No contexto deste trabalho, a escolha de arquiteturas de 32 bits, especificamente o ESP32, justifica-se pela necessidade de processamento concorrente: o dispositivo deve gerenciar a leitura de sensores via interrupções de hardware enquanto mantém ativa a pilha de protocolos de comunicação. Ademais, a capacidade de operar o protocolo LoRa fez com que a plataforma ESP32 se destacasse frente a MCUs tradicionais de 8 bits (como Arduino).

A arquitetura interna do ESP32 é apresentada na Figura 2. O diagrama evidencia a integração de dois núcleos de processamento (Dual-Core Xtensa LX6 32-bit), módulos de rádio (Wi-Fi/Bluetooth) e periféricos críticos como o RTC (*Real-Time Clock*), que permite o gerenciamento avançado de energia (*Deep Sleep*).

Figura 2 – Diagrama de blocos funcional do SoC ESP32.



Fonte: Espressif Systems (Datasheet oficial).

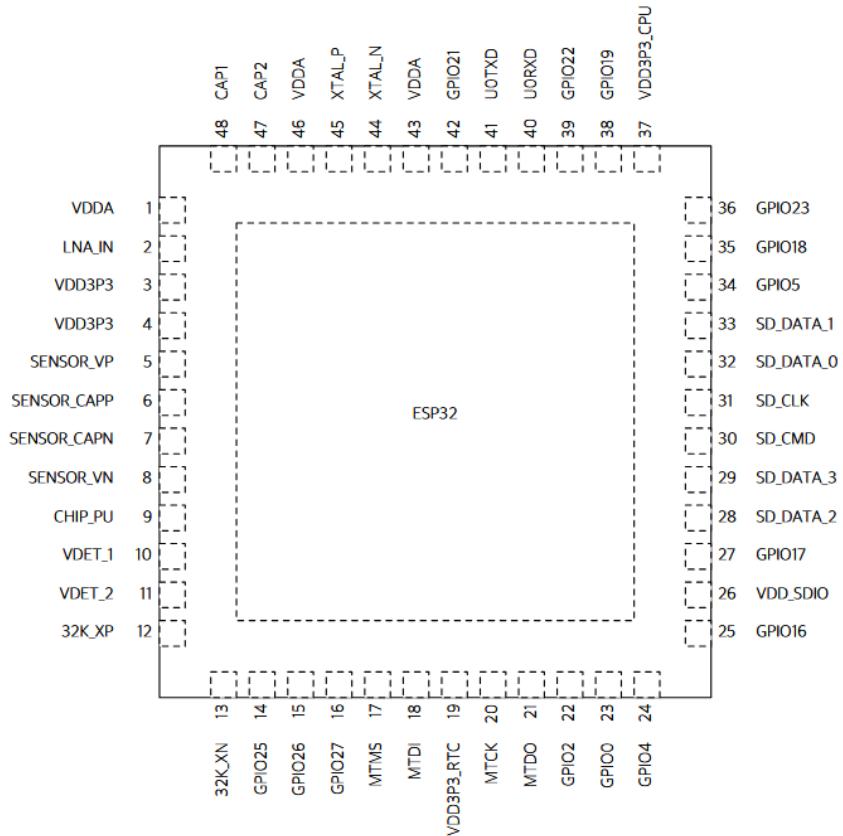
A interface com o mundo físico ocorre através do encapsulamento e distribuição de pinos (Figura 3). A maioria dos pinos possui função multiplexada, podendo ser configurados via *software* como entradas digitais, canais de conversão ADC ou linhas de comunicação serial. Essa flexibilidade é um outro fator que torna o ESP32 adequado para aplicações IoT, onde a diversidade de sensores e atuadores exige múltiplas interfaces.

2.2.2 Princípios de Transdução e Sensores

Sensores são dispositivos transdutores que convertem grandezas físicas em sinais elétricos mensuráveis. No contexto agrícola, sensores de umidade do solo são cruciais para monitorar a disponibilidade hídrica às plantas. Esses sensores podem ser classificados em duas categorias principais:

- **Sensores Analógicos:** Retornam uma tensão variável (0 a 3.3V) que deve ser discretizada pelo Conversor Analógico-Digital (ADC) do microcontrolador, presente no diagrama de blocos do ESP32 (Figura 2).
- **Sensores Digitais:** Possuem circuitos integrados que realizam a conversão internamente e transmitem o dado via barramento serial.

Figura 3 – Layout de pinos do encapsulamento do ESP32.



Fonte: Espressif Systems (Datasheet oficial).

2.2.3 Interfaces de Comunicação Periférica

A comunicação interna no nó sensor (entre o MCU e seus sensores ou transceptores de rádio) ocorre através de protocolos seriais:

- **UART (Universal Asynchronous Receiver-Transmitter):** Protocolo assíncrono ponto-a-ponto, fundamental para depuração e comunicação com módulos GPS.
 - **I2C (Inter-Integrated Circuit):** Barramento síncrono de dois fios (SDA/SCL), utilizado para conectar múltiplos sensores digitais.
 - **SPI (Serial Peripheral Interface):** Protocolo síncrono de alta velocidade (*full-duplex*), essencial para a comunicação com o transceptor LoRa, que exige alta vazão de dados e determinismo temporal.

2.3 Sensoriamento Remoto (SR)

O SR baseia-se na interação da radiação eletromagnética com a superfície terrestre. Para compreender a extração de informações das imagens, é necessário analisar o processo físico de

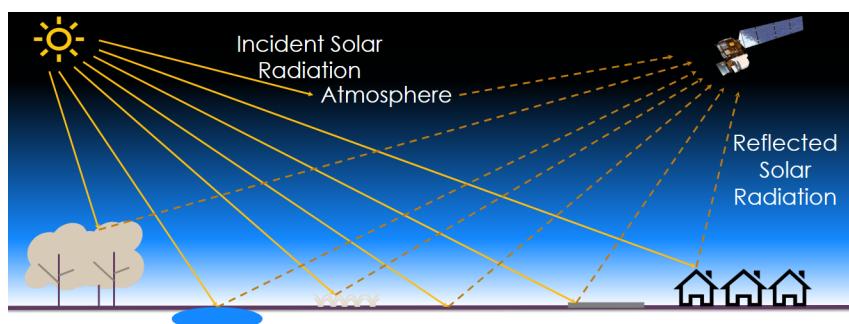
aquisição. Com isso, SR se trata de uma área da geociêncas, engenharia e ciências ambientais, que estuda a obtenção de informações sobre objetos ou áreas à distância, geralmente por meio de satélites ou aeronaves equipadas com sensores especializados.

2.3.1 Processo Físico de Formação da Imagem

A geração de uma imagem de satélite passivo óptico (como Sentinel-2) segue um fluxo físico complexo:

1. **Fonte e Interação:** O Sol emite radiação que atravessa a atmosfera e incide sobre o alvo. Parte dessa energia é absorvida, transmitida ou refletida em direção ao sensor.
2. **Radiância no Topo da Atmosfera (TOA):** O sensor mede a radiância total (L), que inclui a luz refletida pelo alvo e a dispersão atmosférica.
3. **Conversão Radiométrica e Atmosférica:** Para análise temporal, aplica-se a **Correção Atmosférica**, convertendo os dados brutos em **Refletância de Superfície (BOA - Bottom of Atmosphere)**, removendo efeitos de aerossóis e vapor d'água ([CLAVIERE et al., 2018](#)).

Figura 4 – Processo físico de formação da imagem de sensoriamento remoto pela fonte solar.



Fonte: ([NASA, 2023](#)).

A Figura 4 ilustra o processo de formação da imagem em sensores passivos, destacando a interação da radiação solar com a atmosfera e a superfície terrestre. Os sensores são calibrados para medir a radiância refletida em diferentes bandas espectrais, permitindo a análise detalhada das características do alvo. No entanto, esse processo é suscetível a interferências atmosféricas, o que reforça a importância da correção atmosférica para garantir a precisão dos dados obtidos ([NASA, 2023](#)).

2.3.2 Índices Espectrais de Vegetação e Água

Os índices espectrais são operações algébricas entre bandas, projetadas para realçar características de interesse ([TRAN; REEF; ZHU, 2022](#)).

2.3.2.1 NDVI (*Normalized Difference Vegetation Index*)

Indicador consolidado para vigor vegetativo, baseado no contraste entre a absorção de clorofila no Vermelho (R) e a reflectância da estrutura celular no Infravermelho Próximo (NIR). Seu valor é calculado pela equação:

$$NDVI = \frac{\rho_{NIR} - \rho_R}{\rho_{NIR} + \rho_R} \quad (2.1)$$

A variação do NDVI ao longo do tempo permite monitorar o crescimento das culturas e identificar áreas de estresse hídrico. Portanto, é um índice fundamental para a agricultura de precisão e para o manejo hídrico eficiente.

2.3.2.2 NDWI (*Normalized Difference Water Index*)

Visa delinear corpos hídricos ou estresse na vegetação, utilizando os valores das bandas verde e o infravermelho, conforme a fórmula:

$$NDWI = \frac{\rho_{Green} - \rho_{NIR}}{\rho_{Green} + \rho_{NIR}} \quad (2.2)$$

Valores positivos indicam presença de água ou alta umidade, enquanto valores negativos sugerem solo seco ou vegetação estressada. Variações como o MNDWI substituem o NIR pelo SWIR para maior precisão em certas condições. No entanto, esse índice é sensível a interferências atmosféricas, o que reforça a importância da correção atmosférica para garantir a precisão dos dados obtidos.

2.4 Aprendizado de Máquina (*Machine Learning*)

O Aprendizado de Máquina (ML) é o subcampo da Inteligência Artificial que tem como objetivo o desenvolvimento de algoritmos capazes de aprender padrões a partir de dados, sem a necessidade de programação explícita para cada tarefa específica. Esses algoritmos são treinados em conjuntos de dados para identificar relações complexas e fazer previsões ou classificações com base em novas entradas.

2.4.1 Tipos de Aprendizado

- **Aprendizado Supervisionado:** O algoritmo é treinado com dados rotulados (entrada e saída conhecida) para aprender uma função de mapeamento $y = f(x)$.
- **Aprendizado Semi-Supervisionado:** Combina dados rotulados e não rotulados para melhorar o desempenho do modelo quando a rotulagem é cara ou limitada.

- **Aprendizado Não-Supervisionado:** O algoritmo busca estruturas ocultas em dados não rotulados, como o agrupamento (*clustering*) de áreas similares.
- **Aprendizado por Reforço:** O agente aprende a tomar decisões sequenciais através de recompensas ou penalidades, útil para otimização de estratégias ao longo do tempo.

2.4.2 Tarefas e Fusão de Dados

No tangente à fusão de dados de IoT e sensoriamento remoto, as tarefas de ML mais relevantes incluem:

- **Regressão:** Modelagem de variáveis contínuas, a partir de características extraídas dos dados. No contexto deste trabalho, a regressão pode ser utilizada para estimar a umidade do solo com base em índices espectrais e dados de sensores IoT.
- **Classificação:** Identificação de estados discretos, para conseguir classificar um dado. Na tentativa de inserir classificação ao escopo deste trabalho, descata-se na aplicação dos níveis de estresse hídrico (baixo, médio, alto) com base nas múltiplas fontes de dados.
- **Redução de Dimensionalidade:** Técnicas como PCA (*Principal Component Analysis*) para extrair as características mais relevantes e reduzir o ruído nos dados.

A abordagem de ML permite integrar efetivamente as diferentes resoluções espaço-temporais e características dos dados de IoT e sensoriamento remoto, gerando modelos preditivos robustos para o manejo hídrico.

3 Desenvolvimento

Esta seção descreve os materiais e os métodos a serem empregados no estudo, considerando dois caminhos complementares de obtenção de dados: (A) uso de *datasets* existentes e (B) coleta em campo com rede própria baseada em LoRaWAN. Ao final, apresenta-se o cronograma das atividades planejadas.

3.1 Materiais

Pensando nos materiais utilizados para o desenvolvimento, devido à incerteza na extração dos dados utilizados para o estudo, pensou-se em utilizar duas temáticas: dados e *hardware*.

3.1.1 Dados

A utilização dos dados nesse estudo é fundamental. Ter um bom conjunto de dados para fazer a sua separação para treinar e testar o modelo desenvolvido, terá relação direta no impacto deste projeto. No entanto, devido ao impedimento de ir a campo para coletar as amostras, pensou-se em dois caminhos.

Caminho A — *Dataset* existente

- Séries históricas e/ou *datasets* acadêmicos contendo variáveis de solo/umidade e apoio meteorológico;
- Meteorologia (INMET/SIMEPAR ou estação local);
- Sensoriamento remoto: Sentinel-2 (MSI), Landsat-8/9 (OLI/TIRS) e Sentinel-1 (SAR);
- Dados vetoriais: limites de talhão, rede de drenagem, solos e corpos d’água.

Caminho B — Coleta em campo (rede própria)

- Amostra piloto em 1–2 talhões, com medições de umidade do solo e temperatura/umidade do ar;
- Registros de validação manual (checklist de campo; amostras pontuais).

3.1.2 *Hardware* e comunicação (Caminho B)

- Microcontrolador **ESP32** com suporte a **LoRa**;
- **Gateway LoRaWAN** (TTN/ChirpStack) ou concentrador disponível;

- Sensores: umidade do solo (capacitivo/tensiômetro), temperatura e umidade relativa do ar;
- Antenas, caixa com proteção de entrada, cabeamento, fonte/bateria.

3.1.3 Software e serviços

- Ambiente Python (venv/conda); bibliotecas: GDAL/rasterio, SNAP/Sen2Cor, ou ainda Google Earth Engine;
- Telemetria (Caminho B): The Things Stack/TTN, MQTT/HTTP, scripts de ingestão;
- Ciência de dados e visualização: numpy, pandas, scikit-learn, QGIS, dash ou streamlit.

3.1.4 Organização e gestão de dados

- Estrutura de pastas: raw/, interim/, processed/, models/, reports/;
- Metadados (CSV/Parquet): sensor, lat, lon, data/hora local, DOY, QA flags, CRS;
- Controle de versão: Git/GitHub e possivelmente *Data Version Control* (DVC) para grandes volumes de dados.

3.2 Métodos

3.2.1 Gate de decisão (Mês 1–2)

1. Verificar disponibilidade e suficiência de datasets existentes (variáveis, período, frequência);
2. Se suficiente: adotar **Caminho A** para acelerar a modelagem; caso contrário, ativar **Caminho B** para coleta em campo com LoRaWAN.

3.2.2 Delineamento experimental

- Área de estudo (município/UTM/bioma) e talhões;
- Período de análise (safra/estação);
- Variáveis mínimas: umidade do solo, T/UR do ar;
- Unidades de análise: pixel (10–30 m), ponto de sensor e talhão.

3.2.3 Aquisição de dados

Caminho A — Dataset existente

- Curadoria: fonte, licença, cobertura temporal/espacial, variáveis e qualidade;
- Harmonização: fuso/horário local, DOY e unidades;
- Integração de meteorologia e vetoriais do talhão.

Caminho B — Coleta em campo (ESP32 + LoRaWAN)

- Topologia: nós ESP+LoRa → gateway LoRaWAN → servidor (TTN/ChirpStack);
- *Payload*: `id_no`, `timestamp` local, `umidade_solo`, T/UR, (opcional) pressão/vazão, bateria;
- Amostragem: leitura a cada 5 min; agregações a cada 15–60 min para modelagem;
- Calibração: teste de bancada e checagens periódicas (curva de umidade; sensores de referência);
- Ingestão: *uplink* → webhook/MQTT → banco ou CSV (com logs de perda/retransmissão).

3.2.4 Sensoriamento remoto (comum aos caminhos A e B)

- Critérios: nuvem < $X\%$, coleção L2A (S2)/C2 (L8/9), janelas de revisita;
- Óptico: correção atmosférica (Sen2Cor), máscara nuvem/sombra, recorte ao talhão;
- SAR: calibração radiométrica, correção de terreno, co-registro S1↔S2;
- Derivação: NDWI/MNDWI (água), NDVI/NDMI (vigor/umidade) e, quando aplicável, LST/ET;
- Harmonização: HLS para densificar séries; reprojeção para EPSG do projeto.

3.2.5 Fusão espaço-temporal

- Alinhamento temporal/espacial: grade comum (10–30 m), DOY/hora local; *gap-filling* via composições/HLS;
- Níveis de fusão:
 - *Sensor-level*: reamostragem/registro S1–S2–L8/9 ↔ pontos/talhões;
 - *Feature-level*: *feature set* com índices SR + agregados IoT + clima (defasagens/janelas);
- QA/QC integrado: QA de nuvem/sombra, *outliers* IoT, sincronização de relógio, auditoria de processamento.

3.2.6 Modelagem e produtos

- *Baselines*: regressão (umidade/ET) e classificação (água/estresse);
- Pós-processamento: suavização temporal, morfologia espacial, máscaras operacionais;
- Produtos: GeoTIFF/COG por período, camadas temáticas e *mapa de recomendação de irrigação*.

3.2.7 Validação

- Esquema espaço-temporal: treino/validação/teste por talhão/tempo;
- Métricas: RMSE/MAE (contínuo), F1/IoU (segmentação água/estresse) e *gain* operacional (economia de água);
- Validação de campo (se Caminho B): pontos independentes + registros operacionais de irrigação.

3.2.8 Reprodutibilidade e ética

- *Pipelines* automatizados (Make/CLI), reprodutibilidade (semente fixa) e arquivo de dependências;
- Anonimização/localização aproximada quando necessário; limites de uso dos dados.

3.3 Cronograma de atividades

O Tabela 1 apresenta o planejamento em meses corridos, incluindo o *gate* de decisão (Caminho A vs. B).

Tabela 1 – Cronograma das atividades do Trabalho de Conclusão de Curso (TCC).

Atividade	M1	M2	M3	M4	M5	M6
Gate de decisão (A vs. B)	X	X				
Instalação/Calibração (se B)		X	X			
Coleta IoT contínua (se B)			X	X	X	X
Aquisição + pré-processamento SR (A e B)		X	X	X		
Fusão (alinhamento + <i>features</i>)			X	X		
Modelagem <i>baseline</i>				X	X	
Validação + ajustes					X	X
Produtos + escrita do TCC					X	X

Fonte: Autoria Própria

Marcos (milestones). M2: decisão tomada (A ou B) com plano fechado de dados; M4: *dataset* de fusão pronto e primeiros mapas; M6: validação concluída e materiais do TCC consolidados.

4 Resultados e Discussão

5 Conclusão

Referências

CLAVERIE, M. et al. The harmonized landsat and sentinel-2 surface reflectance data set. *Remote Sensing of Environment*, v. 219, p. 145–161, 2018. Acessado em: 13 nov. 2025. Disponível em: <<https://ntrs.nasa.gov/citations/20190028663>>. Citado na página 33.

FAO. *The State of Food and Agriculture 2022: Leveraging automation in agriculture for transforming agrifood systems*. Rome, 2022. Acessado em 07 nov. 2025. Disponível em: <<https://doi.org/10.4060/cb9479en>>. Citado na página 21.

FAROOQ, M. S.; AKRAM, U. Iot in agriculture: Challenges and opportunities. *Journal of Agricultural Research*, 2021. Acessado em: 12 nov. 2025. Disponível em: <<http://jaragri.com-jar/index.php/jar/article/view/180>>. Citado na página 30.

FAROOQ, M. S. et al. A survey on the role of iot in agriculture for the implementation of smart livestock environment. *IEEE Access*, v. 10, 2022. Acessado em: 13 nov. 2025. Disponível em: <<https://ieeexplore.ieee.org/document/9681084>>. Citado na página 22.

GOMES, J. P. d. T.; INNOCENTINI, M. D. M.; FORMIGONI, C. E. Utilização da iot na agricultura sustentável. *Anais da 15ª Jornada Científica e Tecnológica do IFSULDEMINAS*, v. 15, n. 3, 2023. Acessado em: 13 nov. 2025. Disponível em: <<https://josif.ifsuldeminas.edu.br/ojs/index.php/anais/article/view/855/727>>. Citado 2 vezes nas páginas 22 e 25.

HAKIRI, A. et al. Publish/subscribe-enabled software defined networking for efficient and scalable iot communications. *Communications Magazine, IEEE*, v. 53, p. 48–54, 09 2015. Citado 2 vezes nas páginas 29 e 30.

KUMAR, P. et al. A comprehensive review on smart and sustainable agriculture using iot technologies. *Smart Agricultural Technology*, v. 6, p. 100401, 2024. Acessado em: 13 nov. 2025. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2772375524000923>>. Citado 3 vezes nas páginas 22, 23 e 29.

MASCHIETTO, L. G. et al. *Arquitetura e infraestrutura de IoT*. Porto Alegre: SAGAH, 2021. ISBN 978-65-5690-194-7. Citado 2 vezes nas páginas 29 e 30.

MUTURI, J. W.; NDEHEDEHE, C. E.; KENNARD, M. J. A review of the use of remote sensing techniques in assessing irrigation water use. *Agricultural Water Management*, v. 319, p. 109759, 2025. Acessado em: 18 nov. 2025. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0378377425004731>>. Citado 3 vezes nas páginas 23, 24 e 25.

NASA. *Spectral Indices for Land and Aquatic Applications*. 2023. Acessado em: 20 nov. 2025. Disponível em: <https://appliedsciences.nasa.gov/sites/default/files/2023-10/Spectral_Indices_Part1.pdf>. Citado na página 33.

ROCHA, L. O. d. S.; GUIMARÃES, C. R. R.; OLIVEIRA, R. A. P. d. Exploração do uso eficiente de recursos hídricos na agricultura: investigação de técnicas de irrigação e tecnologias para a minimização do desperdício de água. *Revista Foco*, v. 17, n. 4, p. e4950, 2024. Acessado

em 07 nov. 2025. Disponível em: <<https://doi.org/10.54751/revistafoco.v17n4-128>>. Citado 3 vezes nas páginas [21](#), [23](#) e [25](#).

RODRIGUES, H. et al. Remote and proximal sensors data fusion: Digital twins in irrigation management zoning. *Sensors*, v. 24, p. 5742, 2024. Acessado em: 18 nov. 2025. Disponível em: <<https://doi.org/10.3390/s24175742>>. Citado 2 vezes nas páginas [24](#) e [25](#).

TRAN, T. V.; REEF, R.; ZHU, X. A review of spectral indices for mangrove remote sensing. *Remote Sensing*, v. 14, n. 19, 2022. ISSN 2072-4292. Disponível em: <<https://www.mdpi.com/2072-4292/14/19/4868>>. Citado na página [33](#).

TRINTA, M. A.; CESAR, F.; PANTOJA, C. E. Gerenciamento autônomo de uma agricultura utilizando sistema multiagente em uma arquitetura iot. *Revista Eletrônica de Iniciação Científica em Computação*, v. 19, n. 1, 2021. Acessado em: 18 nov. 2025. Disponível em: <<https://journals-sol.sbc.org.br/index.php/reic/article/view/1777>>. Citado 2 vezes nas páginas [23](#) e [25](#).

WANG, J. et al. Integration of remote sensing and machine learning for precision agriculture: A comprehensive perspective on applications. *Agronomy*, v. 14, p. 1975, 2024. Acessado em 08 nov. 2025. Disponível em: <<https://doi.org/10.3390/agronomy14091975>>. Citado 3 vezes nas páginas [21](#), [24](#) e [25](#).