



Fernando Daniel Marcelino

**Sistema de Agricultura de Precisão para o Manejo
Sustentável de Recursos Hídricos baseado na Fusão
de Dados de Sensores IoT e Imagens de Satélite**

São José dos Campos, SP

Fernando Daniel Marcelino

Sistema de Agricultura de Precisão para o Manejo Sustentável de Recursos Hídricos baseado na Fusão de Dados de Sensores IoT e Imagens de Satélite

Trabalho de conclusão de curso apresentado ao Instituto de Ciência e Tecnologia – UNIFESP, como parte das atividades para obtenção do título de Bacharel em Engenharia de Computação.

Universidade Federal de São Paulo – UNIFESP

Instituto de Ciência e Tecnologia

Bacharelado em Engenharia de Computação

Orientador: Profa. Dra. Fernanda Quelho Rossi

São José dos Campos, SP

Dezembro de 2025

Este trabalho é dedicado a ...

Agradecimentos

Esta monografia eu dedico à minha família e em especial aos meus pais, Edmilson Aparecido Marcelino e Lucineia Domingues Marcelino, que dedicaram seus esforços para a minha educação. ...

*“A educação é a arma mais poderosa
que você pode usar para mudar o mundo.”
(Nelson Mandela)*

Resumo

A escassez e a distribuição desigual dos recursos hídricos colocam a agricultura sob forte pressão para produzir mais, com menor desperdício de água e menor impacto ambiental. Diante desse cenário, e em consonância com os Objetivos de Desenvolvimento Sustentável (ODS 2, 6 e 12), esta monografia descreve o projeto de um sistema de agricultura de precisão para o manejo sustentável de recursos hídricos, fundamentado na integração de duas fontes principais de informação: medições de redes de sensores IoT em campo e dados de sensoriamento remoto orbitais. O trabalho aborda, inicialmente, os fundamentos teóricos de Internet das Coisas, sensoriamento remoto e fusão de dados, com ênfase em sensores de umidade do solo, índices espectrais derivados de imagens multiespectrais e produtos de missões espaciais como Sentinel e Landsat. Em seguida, é proposta uma arquitetura em camadas que abrange aquisição, transmissão, armazenamento e tratamento de dados, incluindo rotinas de pré-processamento e sincronização temporal. A partir desse fluxo, são definidos conjuntos de atributos que combinam variáveis de solo, clima e informações espectrais para alimentar modelos de aprendizado de máquina voltados à estimativa de indicadores de estado hídrico e à geração de mapas de recomendação de irrigação em nível de talhão. Complementarmente, delinea-se a implementação de um protótipo de interface visual para apoio à decisão, capaz de apresentar mapas, séries temporais e alertas de forma intuitiva. Como contribuição, o trabalho organiza boas práticas de projeto de dados, documenta uma metodologia de fusão IoT–satélite e oferece uma base estruturada para desenvolvimentos futuros em irrigação inteligente e agricultura de precisão sustentável.

Palavras-chave: agricultura de precisão; recursos hídricos; irrigação inteligente; Internet das Coisas; sensoriamento remoto.

Abstract

Water scarcity and the uneven distribution of water resources place agriculture under strong pressure to increase production while reducing water waste and environmental impacts. In this context, and in accordance with the Sustainable Development Goals (SDGs 2, 6 and 12), this monograph describes the design of a precision agriculture system for sustainable water resources management, grounded in the integration of two main sources of information: measurements from in-field IoT sensor networks and orbital remote sensing data. The work first discusses the theoretical foundations of the Internet of Things, remote sensing and data fusion, with emphasis on soil moisture sensors, spectral indices derived from multispectral imagery and products from space missions such as Sentinel and Landsat. Next, a layered architecture is proposed, covering data acquisition, transmission, storage and processing, including preprocessing routines and temporal synchronization. Based on this flow, feature sets are defined that combine soil, climate and spectral variables to feed machine learning models aimed at estimating indicators of crop water status and generating irrigation recommendation maps at field level. Additionally, the implementation of a visual decision-support prototype is outlined, capable of presenting maps, time series and alerts in an intuitive way. As its main contributions, this work organizes data-project best practices, documents a methodology for IoT–satellite data fusion and provides a structured basis for future developments in smart irrigation and sustainable precision agriculture.

Key-words: precision agriculture; water resources; smart irrigation; Internet of Things; remote sensing.

Lista de ilustrações

Lista de tabelas

Tabela 1 – Cronograma das atividades do TCC.	34
------------------------------------------------------	----

Lista de abreviaturas e siglas

API	Application Programming Interface (Interface de Programação de Aplicações)
IDE	<i>Integrated Development Environment</i> (Ambiente de Desenvolvimento Integrado)
RF	Rádio Frequência
ULA	Unidade de Lógica e Aritmética

Lista de símbolos

m	Massa do veículo
x	Posição do veículo
θ	Ângulo de ataque do veículo
Ω	Ohm

Sumário

1	Introdução	21
1.1	Trabalhos Correlatos	22
1.1.1	IoT na agricultura: de revisões gerais a aplicações em campo	22
1.1.2	Sensoriamento remoto e gestão hídrica na agricultura	23
1.1.3	Fusão de sensores próximos e remotos no manejo da irrigação	24
1.1.4	Síntese crítica e relação com o trabalho proposto	25
1.2	Definição do Problema	25
1.3	Objetivos	26
1.3.1	Objetivo Geral	26
1.3.2	Objetivos Específicos	26
1.4	Estrutura do Texto	26
2	Fundamentação Teórica	27
2.1	Internet das Coisas (IoT)	27
2.2	Sensoriamento remoto aplicado ao manejo hídrico	28
2.2.1	Plataformas, sensores e resoluções relevantes	28
2.2.2	Pré-processamento e qualidade dos dados	28
2.2.3	Índices e produtos para água, vegetação e umidade	29
2.2.4	Diretrizes para fusão de sensoriamento remoto e IoT no manejo hídrico	29
3	Desenvolvimento	31
3.1	Materiais	31
3.1.1	Dados	31
3.1.2	<i>Hardware</i> e comunicação (Caminho B)	31
3.1.3	<i>Software</i> e serviços	32
3.1.4	Organização e gestão de dados	32
3.2	Métodos	32
3.2.1	<i>Gate</i> de decisão (Mês 1–2)	32
3.2.2	Delineamento experimental	32
3.2.3	Aquisição de dados	33
3.2.4	Sensoriamento remoto (comum aos caminhos A e B)	33
3.2.5	Fusão espaço-temporal	33
3.2.6	Modelagem e produtos	34
3.2.7	Validação	34
3.2.8	Reprodutibilidade e ética	34
3.3	Cronograma de atividades	34

4 Resultados e Discussão 35

5 Conclusão 37

Referências 39

Apêndices 41

APÊNDICE A Título do Apêndice 43

Anexos 45

ANEXO A Título do Anexo 47

1 Introdução

Nas últimas décadas, o aumento da demanda global por alimentos e a intensificação da agricultura têm elevado a pressão sobre os recursos naturais, especialmente a água. Esse recurso, essencial para a manutenção da vida e para a produção agrícola, vem sofrendo escassez em diversas regiões, o que tem intensificado a busca por soluções que promovam o uso racional e sustentável da água (FAO, 2022). Essa preocupação está diretamente alinhada aos Objetivos de Desenvolvimento Sustentável (ODS) estabelecidos pela Agenda 2030 da Organização das Nações Unidas (ONU), em especial os ODS de números 2, 6 e 12, que visam assegurar a segurança alimentar, melhorar o manejo hídrico e promover práticas agrícolas sustentáveis. Nesse contexto, a gestão eficaz e sustentável da água na agricultura não é apenas uma necessidade técnica, mas uma demanda decisiva para garantir a estabilidade ambiental e social (ROCHA; GUIMARÃES; OLIVEIRA, 2024).

Ao mesmo tempo, o avanço das tecnologias digitais aplicadas à agricultura, como o sensoriamento remoto e a Internet das Coisas (IoT), tem possibilitado a coleta massiva de dados ambientais e produtivos, abrindo novas oportunidades para o aprimoramento do manejo hídrico e o aumento da eficiência no uso da água. Entretanto, observa-se que a adoção dessas tecnologias ainda ocorre de forma fragmentada, impedindo uma visão integrada e em tempo quase real da dinâmica hídrica nas lavouras. Segundo Wang et al. (2024), apesar do progresso obtido pela combinação de sensores de solo, dados de satélite e técnicas de aprendizado de máquina, persistem desafios relacionados à qualidade, à padronização e à interoperabilidade das informações — fatores que comprometem a construção de modelos generalizáveis para a agricultura de precisão. Essa falta de integração entre diferentes fontes de dados limita a geração de produtos aplicáveis, como mapas de irrigação e relatórios de recomendação, que são essenciais para orientar práticas agrícolas mais eficientes e ambientalmente responsáveis.

Diante desse cenário, o presente estudo propõe o desenvolvimento de uma metodologia de fusão de dados que combine informações provenientes de sensores IoT e de imagens de satélite, utilizando técnicas de aprendizado de máquina para gerar recomendações precisas e dinâmicas de irrigação. Essa abordagem busca superar as lacunas existentes na integração e automação de dados agrícolas, promovendo uma visão mais completa e multiescalar do comportamento hídrico das áreas cultivadas. Ao conectar o desafio global da sustentabilidade hídrica às oportunidades proporcionadas pela inovação tecnológica, esta pesquisa se apresenta como uma contribuição concreta à agricultura de precisão sustentável, fortalecendo o compromisso com o uso racional dos recursos naturais e com os objetivos propostos pela Agenda 2030.

1.1 Trabalhos Correlatos

Após a contextualização apresentada, que evidencia a pressão crescente sobre os recursos hídricos e o alinhamento do tema aos Objetivos de Desenvolvimento Sustentável (ODS 2, 6 e 12), e de toda fundamentação teórica, que definiu os conceitos de Internet das Coisas (IoT) e sensoriamento remoto aplicados ao manejo hídrico, esta seção discute trabalhos que efetivamente aplicam essas tecnologias em contextos agrícolas.

Os estudos selecionados foram organizados em três eixos: (i) IoT na agricultura, desde revisões gerais até aplicações em campo; (ii) sensoriamento remoto e gestão hídrica; e (iii) fusão de sensores próximos e remotos. Em conjunto, esses trabalhos ajudam a explicitar a lacuna que esta monografia busca abordar: a integração sistemática entre dados de redes de sensores IoT e produtos de sensoriamento remoto para apoiar decisões de irrigação em agricultura de precisão.

1.1.1 IoT na agricultura: de revisões gerais a aplicações em campo

Em consonância com a discussão sobre o papel da IoT na agricultura 4.0, [Kumar et al. \(2024\)](#) apresentam uma revisão extensa sobre o uso de tecnologias de IoT na agricultura inteligente e sustentável. Os autores descrevem arquiteturas em camadas (sensoriamento, comunicação e aplicação), tipos de sensores (solo, clima, planta), protocolos de comunicação (Wi-Fi, LoRa, ZigBee, entre outros) e plataformas em nuvem para armazenamento e análise de dados. O survey também destaca aplicações como irrigação inteligente, monitoramento de condições ambientais, rastreabilidade e automação de operações agrícolas, associando-as a ganhos em eficiência de uso de insumos, produtividade e sustentabilidade. Ao mesmo tempo, aponta desafios recorrentes, como limitações de conectividade em áreas rurais, interoperabilidade entre dispositivos heterogêneos, segurança, privacidade e modelos de negócio para adoção em larga escala ([KUMAR et al., 2024](#)).

Focando especificamente sistemas pecuários, mas com pertinência técnica ao contexto agrícola em geral, [Farooq et al. \(2022\)](#) realizam um survey sobre o papel da IoT na implementação de ambientes de pecuária inteligente. O trabalho discute de forma detalhada a infraestrutura de redes IoT, arquiteturas em camadas, topologias e protocolos de comunicação, bem como desafios de escalabilidade, consumo energético, robustez da comunicação sem fio e padronização. São apresentados casos de uso envolvendo sensores vestíveis, coleiras inteligentes e nós distribuídos para monitoramento de saúde, bem-estar e produtividade dos animais. Embora o foco seja a produção animal, os pontos críticos levantados – sobretudo no que se refere à confiabilidade da rede e à gestão de grandes volumes de dados – são análogos aos enfrentados por redes de sensores de solo e clima, reforçando aspectos sobre os limites e potencialidades da IoT em ambientes rurais ([FAROOQ et al., 2022](#)).

No contexto da agricultura familiar brasileira, [Gomes, Innocentini e Formigoni \(2023\)](#) propõem uma solução de baixo custo baseada em IoT para monitoramento agroclimático e su-

porte à irrigação sustentável, aproximando os conceitos discutidos na revisão de [Kumar et al. \(2024\)](#) de uma realidade de pequena escala, fundamental para o presente estudo. O sistema integra sensores de umidade e temperatura do ar e do solo, sensores de vazão e atuadores de irrigação a um software supervisor de código aberto (ScadaBR), com armazenamento dos dados em banco MySQL. Implantada em horta experimental no Sul/Sudoeste de Minas Gerais, a solução apresenta boa concordância entre os dados coletados e informações meteorológicas oficiais do INMET, evidenciando potencial para apoiar decisões de irrigação e reduzir desperdícios de água em propriedades com restrições de capital ([GOMES; INNOCENTINI; FORMIGONI, 2023](#)). Este estudo reforça, de forma prática, a viabilidade de arquiteturas acessíveis e abertas para o contexto de agricultura familiar e para estudo em pequeno porte.

[Trinta, Cesar e Pantoja \(2021\)](#) avançam na direção da automatização da irrigação, ao apresentar um sistema autônomo de gerenciamento baseado em uma arquitetura com Sistema Multiagente (SMA) e IoT. Na solução proposta, um Raspberry Pi executa os agentes responsáveis por tomar decisões a partir de dados coletados por microcontroladores, que leem sensores de solo e clima e acionam atuadores de irrigação. A comunicação ocorre via *middleware* ContextNet, e uma aplicação web permite ao usuário acompanhar o estado do cultivo e intervir quando necessário. Os resultados do estudo de caso indicam que a abordagem com SMA aumenta a autonomia do sistema, possibilitando decisões de irrigação mesmo na ausência de intervenção humana direta e reduzindo a dependência de monitoramento manual ([TRINTA; CESAR; PANTOJA, 2021](#)). Ao trazer a inteligência para a borda da rede, o trabalho se aproxima da proposta desta monografia de utilizar dados de sensores de campo como insumo para decisões automatizadas de manejo hídrico, porém ainda sem integrar explicitamente informações orbitais.

1.1.2 Sensoriamento remoto e gestão hídrica na agricultura

Do ponto de vista da gestão hídrica em escala de sistema produtivo, [Rocha, Guimarães e Oliveira \(2024\)](#) realizam uma revisão sobre técnicas de irrigação e tecnologias voltadas à minimização do desperdício de água na agricultura, retomando a problemática de escassez de recursos. O artigo examina alguns métodos de irrigação (como gotejamento, aspersão e sistemas localizados), além de tecnologias de monitoramento que incluem desde sensores de solo, estações meteorológicas até ferramentas de apoio às decisões. Os autores discutem ganhos em economia de água, energia e fertilizantes, mas ressaltam barreiras relacionadas a custos de implantação, necessidade de capacitação técnica e desigualdade de acesso entre os produtores. Ao defenderem uma abordagem integrada que considere simultaneamente dimensões técnicas, econômicas, sociais e ambientais, reforçam a importância de arranjos tecnológicos como o proposto nesta monografia, que articula IoT e sensoriamento remoto ([ROCHA; GUIMARÃES; OLIVEIRA, 2024](#)).

[Muturi, Ndehedehe e Kennard \(2025\)](#) acrescentam a perspectiva do sensoriamento re-

moto, ao revisarem o uso de técnicas orbitais para estimar o uso de água na irrigação. O estudo mapeia abordagens baseadas em evapotranspiração, umidade do solo, balanço hídrico e fusão de dados de múltiplos sensores, contemplando diferentes escalas espaciais. São discutidos o papel de sensores ópticos, térmicos e de micro-ondas, bem como a importância de séries temporais e de dados de campo para calibração e validação. Entre as lacunas apontadas estão a subexploração de sensores de micro-ondas, a escassez de séries longas e de estudos comparativos, além da necessidade de quantificar incertezas quando essas estimativas subsidiam políticas de alocação de água (MUTURI; NDEHEDEHE; KENNARD, 2025). Essas observações reforçam a relevância de integrar medições locais, como as fornecidas por redes IoT, às estimativas derivadas de imagens de satélite.

Wang et al. (2024) ampliam esse panorama ao discutir a integração entre sensoriamento remoto e algoritmos de aprendizado de máquina na agricultura de precisão, retomando a ênfase no uso de técnicas de inteligência computacional. Os autores sistematizam aplicações que combinam imagens de satélite, sensores hiperespectrais, plataformas aéreas não tripuladas (UAVs) e sensores de proximidade com modelos como máquinas de vetor de suporte, florestas aleatórias e redes neurais profundas. São apresentados exemplos em estimativa de produtividade, detecção de estresse hídrico, mapeamento de atributos de solo e delimitação de zonas de manejo. Ao mesmo tempo, o estudo enfatiza desafios de qualidade e padronização dos dados, interpretabilidade dos modelos e transferência entre regiões com diferentes condições edafoclimáticas (WANG et al., 2024). Esses pontos se alinham com as limitações de generalização e importância do contexto local, reforçando a necessidade de abordagens de fusão que aproveitem dados orbitais e de campo de forma complementar.

1.1.3 Fusão de sensores próximos e remotos no manejo da irrigação

Rodrigues et al. (2024) aproximam-se de forma direta da proposta desta monografia ao explorar a fusão de dados de sensores proximais e remotos para apoio ao zoneamento de manejo de irrigação, articulada ao conceito de “gêmeos digitais”. Em um pivô central de 72 ha no estado de São Paulo, os autores coletam dados de condutividade elétrica aparente do solo com sensor proximal EM38-MK2 em alta densidade e, em seguida, simulam um cenário de amostragem esparsa com menos linhas de coleta, representando uma situação de menor custo operacional. Esses dados são combinados com covariáveis derivadas de modelos digitais de elevação e de imagens dos satélites ALOS PALSAR, ASTER, Sentinel-2 e Landsat 8. Comparando diferentes métodos geoestatísticos e de regressão espacial, o estudo evidencia que a krigagem com deriva externa, alimentada pelas covariáveis de sensoriamento remoto, permite aproximar a acurácia do mapa de referência obtido com amostragem densa, tornando possível definir zonas de manejo de irrigação com menor esforço de campo (RODRIGUES et al., 2024).

Ainda que não utilizem explicitamente redes IoT, os trabalhos de Muturi, Ndehedehe e Kennard (2025), Wang et al. (2024) e Rodrigues et al. (2024) convergem com a Fundamentação

Teórica ao demonstrar que o sensoriamento remoto, combinado a medições locais, é capaz de gerar produtos espaciais – como mapas de uso de água, zonas de manejo e indicadores de estresse hídrico – altamente relevantes para decisões de irrigação. O ponto de tensão que emerge desses estudos, e que se conecta diretamente à lacuna identificada na literatura, é a ausência de arquiteturas bem descritas que integrem de ponta a ponta séries temporais de sensores e informações orbitais em fluxos operacionais de apoio à decisão.

1.1.4 Síntese crítica e relação com o trabalho proposto

Os trabalhos analisados confirmam o panorama delineado: soluções baseadas em IoT evoluíram significativamente rumo ao monitoramento em tempo quase real e à automação da irrigação em nível de propriedade, seja por meio de arquiteturas de baixo custo voltadas à agricultura familiar (GOMES; INNOCENTINI; FORMIGONI, 2023), seja via sistemas com inteligência distribuída, como os baseados em sistemas multiagentes (TRINTA; CESAR; PANTOJA, 2021). Em paralelo, a literatura em sensoriamento remoto e aprendizado de máquina consolidou métodos para estimar evapotranspiração, umidade do solo e uso de água na irrigação, além de delinear zonas de manejo com base em dados orbitais e proximais (ROCHA; GUIMARÃES; OLIVEIRA, 2024; MUTURI; NDEHEDEHE; KENNARD, 2025; WANG et al., 2024; RODRIGUES et al., 2024).

No entanto, a maior parte desses estudos permanece concentrada em um desses eixos de forma isolada: ora enfatizam a infraestrutura de IoT e a lógica de decisão local, ora exploram o potencial do sensoriamento remoto e de modelos preditivos, sem detalhar metodologias de fusão que conciliem a alta frequência temporal dos sensores de campo com a cobertura espacial e multiespectral das imagens de satélite. Assim, embora haja indicações claras do benefício de combinar essas fontes de dados – tanto nas revisões quanto nos estudos aplicados – ainda são relativamente raras as propostas que implementam, validam e documentam arquiteturas completas de integração entre IoT e sensoriamento remoto para apoio operacional à gestão hídrica em escala de talhão.

Diante desse panorama, reafirma-se o espaço de contribuição desta monografia: desenvolver e avaliar um método de fusão de dados entre redes de sensores IoT e produtos de sensoriamento remoto, apoiado em técnicas de aprendizado de máquina, voltado à otimização da gestão hídrica na agricultura de precisão. Ao articular os elementos discutidos na Introdução, na Fundamentação Teórica e nos Trabalhos Correlatos, o estudo busca oferecer uma abordagem integrada que contribua para o uso mais eficiente e sustentável da água, em apoio às diretrizes dos ODS e aos desafios práticos enfrentados em sistemas agrícolas reais.

1.2 Definição do Problema

Descrever o problema que será resolvido e as justificativas.

1.3 Objetivos

1.3.1 Objetivo Geral

O objetivo geral deste trabalho é propor e desenvolver um sistema de agricultura de precisão focado no manejo hídrico sustentável, baseado na fusão de dados de sensores IoT e imagens de satélite, com o propósito de gerar mapas de recomendação de irrigação mais precisos e eficientes.

1.3.2 Objetivos Específicos

Para atingir o objetivo geral proposto, estabelecem-se os seguintes objetivos específicos:

- Revisar a literatura e o estado da arte sobre as tecnologias de IoT, sensoriamento remoto e técnicas de fusão de dados aplicadas à agricultura de precisão;
- Definir a arquitetura do sistema, especificando os componentes de hardware para a coleta de dados e a plataforma de software para ingestão e armazenamento dos dados;
- Definir e estabelecer a metodologia para a aquisição e o processamento de imagens de satélite para a área de estudo;
- Desenvolver um modelo de *machine learning* para realizar a fusão dos dados, correlacionando as medições pontuais e de alta frequência dos sensores IoT com os dados espaciais de baixa frequência das imagens de satélite;
- Implementar um protótipo do sistema que utilize o modelo de fusão para gerar mapas, relatórios ou *dashboards* de recomendação e alerta sobre a irrigação, indicando a variabilidade da necessidade de irrigamento;
- Analisar a eficácia potencial do sistema proposto na redução do desperdício de água e no aumento da eficiência produtiva, validando a metodologia adotada.

1.4 Estrutura do Texto

Os próximos capítulos deste trabalho são organizados da seguinte forma:

- Capítulo 2 apresenta ...
- Capítulo 3 descreve ...
- Capítulo 4 mostra ...
- Capítulo 5 relata ...

2 Fundamentação Teórica

2.1 Internet das Coisas (IoT)

O termo Internet das Coisas (IoT) é utilizado para tratar da comunicação entre máquinas e dispositivos conectados à internet, envolvendo diversas tecnologias para transporte e gerenciamento de dados ([MASCHIETTO et al., 2021](#)). Historicamente, a literatura registra o experimento de John Romkey, em 1990, que conectou uma torradeira à internet para ser acionada remotamente, frequentemente apresentado como um marco inaugural da IoT ([MANCINI, 2017](#)).

No contexto do manejo hídrico na agricultura, a IoT integra sensores de umidade do solo, temperatura, vazão, pressão e outros a plataformas de telemetria e análise, viabilizando observações de alta frequência diretamente no campo e alimentando sistemas de apoio à decisão sobre quando e quanto irrigar, com potencial de reduzir desperdícios de água e custos operacionais ([KUMAR et al., 2024](#); [REJEB et al., 2022](#)).

Quanto às comunicações, a escolha do enlace depende de critérios como alcance, consumo de energia e infraestrutura disponível. Tecnologias como Wi-Fi e ZigBee são adequadas em áreas com rede local estruturada; já as *Low-Power Wide-Area Networks* (LPWAN), como LoRaWAN e NB-IoT, oferecem baixo consumo e ampla cobertura, sendo recorrentes em aplicações de monitoramento de irrigação e outros ambientes produtivos. A literatura também registra o uso de *data loggers* de baixo custo baseados em LoRaWAN em cenários agrícolas ([FAROOQ; AKRAM, 2021](#); [FAROOQ et al., 2022](#)).

Do ponto de vista organizacional e de gestão de dados, interoperabilidade, padronização de metadados e garantia de qualidade são aspectos cruciais para integrar medições provenientes de redes IoT com outras fontes de informação, como dados meteorológicos e imagens de satélite, de modo a sustentar modelos de recomendação generalizáveis ([KUMAR et al., 2024](#); [REJEB et al., 2022](#)). Além disso, revisões recentes enfatizam a importância de questões de segurança e privacidade, da gestão do ciclo de vida dos dispositivos e da validação em escala como frentes prioritárias de pesquisa e desenvolvimento ([REJEB et al., 2022](#); [HUSSEIN et al., 2024](#)).

Por fim, a literatura aplicada indica a viabilidade de soluções de baixo custo para adoção em pequenas propriedades rurais: arquiteturas baseadas em sensores básicos acoplados a atuadores, operando sobre redes de baixo consumo, têm sido reportadas com ganhos potenciais de eficiência no uso da água e lições práticas de implementação e validação em campo ([KUMAR et al., 2024](#); [FAROOQ; AKRAM, 2021](#)).

2.2 Sensoriamento remoto aplicado ao manejo hídrico

O sensoriamento remoto (SR) oferece medições multiescalares — espacial, temporal e espectral — essenciais ao manejo hídrico em agricultura de precisão, permitindo inferir vigor vegetativo, umidade e evapotranspiração, além do mapeamento de água superficial. A literatura recente aponta para o amadurecimento desse campo, com crescimento das aplicações e consolidação de revisões e mapeamentos sistemáticos ([GARCÍA-BERNÁ et al., 2020](#)).

2.2.1 Plataformas, sensores e resoluções relevantes

No domínio óptico multiespectral, o Sentinel-2/MSI disponibiliza 13 bandas (quatro a 10 m, seis a 20 m e três a 60 m) e revisita nominal de aproximadamente 5 dias em constelação, sendo amplamente empregado na derivação de índices espectrais e séries temporais. Os satélites Landsat-8/9 (OLI/TIRS) oferecem resolução espacial de 30 m nas bandas multiespectrais (15 m na banda pancromática) e bandas térmicas de 100 m (reamostradas para 30 m), com revisita combinada de cerca de 8 dias, sendo úteis a análises de água em escala de talhão até bacia hidrográfica.

A combinação Harmonized Landsat and Sentinel-2 (HLS) unifica a refletância de superfície de OLI e MSI, elevando a densidade temporal e a consistência radiométrica para análises multissensor ([CLAVERIE et al., 2018](#)). No domínio de micro-ondas (SAR), o Sentinel-1 (banda C) permite observações diurnas e noturnas, com menor sensibilidade à presença de nuvens, sendo central para a estimativa de umidade do solo e para a continuidade do monitoramento em condições meteorológicas adversas. Estudos recentes exploram abordagens físicas e híbridas, incluindo decomposição polarimétrica e aplicações de aprendizado de máquina ([ROY et al., 2025](#)).

2.2.2 Pré-processamento e qualidade dos dados

Para dados ópticos multiespectrais, boas práticas incluem correção atmosférica (por exemplo, com o Sen2Cor para geração de produtos de refletância de superfície), mascaramento de nuvens e sombras e co-registro entre cenas e sensores. A documentação técnica (*ATBD/Sen2Cor, Scene User Manual*) orienta a configuração de parâmetros e explicita limitações dos produtos.

Em fusões envolvendo Sentinel-1, Sentinel-2 e Landsat, recomenda-se a harmonização radiométrica e geométrica, bem como a reprojeção para o sistema de referência cartográfica do projeto (por exemplo, EPSG:32722), assegurando consistência espacial para a comparação com métricas de campo e para a geração de produtos integrados. Ademais, a inserção e padronização de metadados (sensor, data, ano/dia juliano, horário local, sistema de referência, entre outros) são fundamentais para ampliar a utilidade das cenas em fluxos que envolvam aplicações de inteligência artificial e outras metodologias avançadas.

2.2.3 Índices e produtos para água, vegetação e umidade

Índices espectrais são amplamente utilizados em aplicações de agricultura de precisão. Para água superficial, destaca-se o índice clássico NDWI (GREEN–NIR), que realça lâminas d'água e suprime o fundo terrestre; em áreas urbanas ou com mistura espectral mais complexa, o MNDWI (que substitui o NIR por SWIR) reduz a contaminação por alvos construídos e solo exposto.

Para vegetação, índices como NDVI e EVI são empregados no monitoramento do vigor vegetativo. Já para umidade da vegetação e do solo, índices que utilizam bandas no SWIR (como NDMI e variações do NDWI proposto por Gao) e composições combinando Sentinel-1 e Sentinel-2 ajudam a inferir estresse hídrico, sobretudo quando acoplados a séries temporais térmicas para estimativa de evapotranspiração em algoritmos de balanço de energia, como SEBAL e METRIC ([BASTIAANSEN et al., 1998](#)).

2.2.4 Diretrizes para fusão de sensoriamento remoto e IoT no manejo hídrico

Com base na literatura de sensoriamento remoto e IoT, destacam-se algumas diretrizes gerais para a fusão de dados orbitais e de redes de sensores no contexto do manejo hídrico:

1. **Alinhamento espaço-temporal:** compatibilizar a revisita dos satélites (por exemplo, Sentinel-2 com revisita de aproximadamente 5 dias e Landsat-8/9 com cerca de 8 dias) com a frequência das medições dos sensores IoT, mitigando lacunas por meio de composições HLS ou da assimilação de dados SAR (como Sentinel-1) em períodos com elevada cobertura de nuvens ([CLAVERIE et al., 2018](#)).
2. **Níveis de fusão:** considerar diferentes níveis de integração, desde a fusão em nível de sensor (*sensor-level*, com reamostragem e registro espacial), passando pela fusão em nível de atributos (*feature-level*, combinando índices e estatísticas derivadas de Sentinel-2/Landsat com métricas provenientes de sensores IoT), até a fusão em nível de decisão (*decision-level*, com combinação de saídas de múltiplos modelos). Recomenda-se a adoção de estratégias de validação cruzada espaço-temporal para avaliar a robustez dos modelos ([GARCÍA-BERNÁ et al., 2020](#)).
3. **Qualidade e rastreabilidade:** aplicar rotinas rigorosas de controle de qualidade (máscaras de nuvem e sombra, verificação geométrica, detecção de *outliers*), padronizar metadados (sensor, data, horário local, sistema de referência, entre outros) e manter trilhas de auditoria que garantam a reprodutibilidade das análises.
4. **Indicadores operacionais:** derivar camadas temáticas de interesse para o manejo hídrico, como mapas de água (NDWI/MNDWI), umidade e estresse hídrico (NDMI, composições Sentinel-1–Sentinel-2) e estimativas de evapotranspiração (SEBAL/METRIC),

integrando-as a informações de solo, meteorologia e redes de sensores IoT para gerar mapas de recomendação de irrigação, painéis de monitoramento e alertas operacionais.

3 Desenvolvimento

Esta seção descreve os materiais e os métodos a serem empregados no estudo, considerando dois caminhos complementares de obtenção de dados: (A) uso de *datasets* existentes e (B) coleta em campo com rede própria baseada em LoRaWAN. Ao final, apresenta-se o cronograma das atividades planejadas.

3.1 Materiais

Pensando nos materiais utilizados para o desenvolvimento, devido à incerteza na extração dos dados utilizados para o estudo, pensou-se em utilizar duas temáticas: dados e *hardware*.

3.1.1 Dados

A utilização dos dados nesse estudo é fundamental. Ter um bom conjunto de dados para fazer a sua separação para treinar e testar o modelo desenvolvido, terá relação direta no impacto deste projeto. No entanto, devido ao impedimento de ir a campo para coletar as amostras, pensou-se em dois caminhos.

Caminho A — *Dataset* existente

- Séries históricas e/ou *datasets* acadêmicos contendo variáveis de solo/umidade e apoio meteorológico;
- Meteorologia (INMET/SIMEPAR ou estação local);
- Sensoriamento remoto: Sentinel-2 (MSI), Landsat-8/9 (OLI/TIRS) e Sentinel-1 (SAR);
- Dados vetoriais: limites de talhão, rede de drenagem, solos e corpos d'água.

Caminho B — Coleta em campo (rede própria)

- Amostra piloto em 1–2 talhões, com medições de umidade do solo e temperatura/umidade do ar;
- Registros de validação manual (checklist de campo; amostras pontuais).

3.1.2 *Hardware* e comunicação (Caminho B)

- Microcontrolador **ESP32** com suporte a **LoRa**;
- **Gateway LoRaWAN** (TTN/ChirpStack) ou concentrador disponível;

- Sensores: umidade do solo (capacitivo/tensiométrico), temperatura e umidade relativa do ar;
- Antenas, caixa com proteção de entrada, cabeamento, fonte/bateria.

3.1.3 Software e serviços

- Ambiente Python (venv/conda); bibliotecas: GDAL/rasterio, SNAP/Sen2Cor, ou ainda Google Earth Engine;
- Telemetria (Caminho B): The Things Stack/TTN, MQTT/HTTP, *scripts* de ingestão;
- Ciência de dados e visualização: numpy, pandas, scikit-learn, QGIS, dash ou streamlit.

3.1.4 Organização e gestão de dados

- Estrutura de pastas: `raw/`, `interim/`, `processed/`, `models/`, `reports/`;
- Metadados (CSV/Parquet): *sensor*, *lat*, *lon*, *data/hora local*, *DOY*, *QA flags*, *CRS*;
- Controle de versão: Git/GitHub e possivelmente *Data Version Control* (DVC) para grandes volumes de dados.

3.2 Métodos

3.2.1 Gate de decisão (Mês 1–2)

1. Verificar disponibilidade e suficiência de *datasets* existentes (variáveis, período, frequência);
2. Se suficiente: adotar **Caminho A** para acelerar a modelagem; caso contrário, ativar **Caminho B** para coleta em campo com LoRaWAN.

3.2.2 Delineamento experimental

- Área de estudo (município/UTM/bioma) e talhões;
- Período de análise (safra/estação);
- Variáveis mínimas: umidade do solo, T/UR do ar;
- Unidades de análise: pixel (10–30 m), ponto de sensor e talhão.

3.2.3 Aquisição de dados

Caminho A — Dataset existente

- Curadoria: fonte, licença, cobertura temporal/espacial, variáveis e qualidade;
- Harmonização: fuso/horário local, DOY e unidades;
- Integração de meteorologia e vetoriais do talhão.

Caminho B — Coleta em campo (ESP32 + LoRaWAN)

- Topologia: nós ESP+LoRa → gateway LoRaWAN → servidor (TTN/ChirpStack);
- *Payload*: `id_no`, `timestamp` local, `umidade_solo`, `T/UR`, (opcional) `pressão/vazão`, `bateria`;
- Amostragem: leitura a cada 5 min; agregações a cada 15–60 min para modelagem;
- Calibração: teste de bancada e checagens periódicas (curva de umidade; sensores de referência);
- Ingestão: *uplink* → webhook/MQTT → banco ou CSV (com logs de perda/retransmissão).

3.2.4 Sensoriamento remoto (comum aos caminhos A e B)

- Critérios: $\text{nuvem} < X\%$, coleção L2A (S2)/C2 (L8/9), janelas de revisita;
- Óptico: correção atmosférica (Sen2Cor), máscara nuvem/sombra, recorte ao talhão;
- SAR: calibração radiométrica, correção de terreno, co-registro $S1 \leftrightarrow S2$;
- Derivação: NDWI/MNDWI (água), NDVI/NDMI (vigor/umidade) e, quando aplicável, LST/ET;
- Harmonização: HLS para densificar séries; reprojeção para EPSG do projeto.

3.2.5 Fusão espaço-temporal

- Alinhamento temporal/espacial: grade comum (10–30 m), DOY/hora local; *gap-filling* via composições/HLS;
- Níveis de fusão:
 - *Sensor-level*: reamostragem/registro $S1-S2-L8/9 \leftrightarrow$ pontos/talhões;
 - *Feature-level*: *feature set* com índices SR + agregados IoT + clima (defasagens/janelas);
- QA/QC integrado: QA de nuvem/sombra, *outliers* IoT, sincronização de relógio, auditoria de processamento.

3.2.6 Modelagem e produtos

- *Baselines*: regressão (umidade/ET) e classificação (água/estresse);
- Pós-processamento: suavização temporal, morfologia espacial, máscaras operacionais;
- Produtos: GeoTIFF/COG por período, camadas temáticas e *mapa de recomendação de irrigação*.

3.2.7 Validação

- Esquema espaço-temporal: treino/validação/teste por talhão/tempo;
- Métricas: RMSE/MAE (contínuo), F1/IoU (segmentação água/estresse) e *gain* operacional (economia de água);
- Validação de campo (se Caminho B): pontos independentes + registros operacionais de irrigação.

3.2.8 Reprodutibilidade e ética

- *Pipelines* automatizados (Make/CLI), reprodutibilidade (semente fixa) e arquivo de dependências;
- Anonimização/localização aproximada quando necessário; limites de uso dos dados.

3.3 Cronograma de atividades

O Tabela 1 apresenta o planejamento em meses corridos, incluindo o *gate* de decisão (Caminho A vs. B).

Tabela 1 – Cronograma das atividades do TCC.

Atividade	M1	M2	M3	M4	M5	M6
Gate de decisão (A vs. B)	X	X				
Instalação/Calibração (se B)		X	X			
Coleta IoT contínua (se B)			X	X	X	X
Aquisição + pré-processamento SR (A e B)		X	X	X		
Fusão (alinhamento + <i>features</i>)			X	X		
Modelagem <i>baseline</i>				X	X	
Validação + ajustes					X	X
Produtos + escrita do TCC					X	X

Fonte: Autoria Própria

Marcos (milestones). M2: decisão tomada (A ou B) com plano fechado de dados; M4: *dataset* de fusão pronto e primeiros mapas; M6: validação concluída e materiais do TCC consolidados.

4 Resultados e Discussão

Apresentar os resultados obtidos no projeto desenvolvido e as discussões relevantes sobre estes resultados.

5 Conclusão

Neste capítulo, apresentar a conclusão do trabalho e possíveis trabalhos futuros. Importante iniciar este capítulo apresentando uma síntese do que foi proposto no presente trabalho.

Referências

BASTIAANSEN, W. G. M. et al. A remote sensing surface energy balance algorithm for land (sebal). *Journal of Hydrology*, v. 212–213, p. 198–212, 1998. Acessado em: 15 nov. 2025. Disponível em: <<https://www.sciencedirect.com/science/article/abs/pii/S0022169498002534>>. Citado na página 29.

CLAVERIE, M. et al. The harmonized landsat and sentinel-2 surface reflectance data set. *Remote Sensing of Environment*, v. 219, p. 145–161, 2018. Acessado em: 13 nov. 2025. Disponível em: <<https://ntrs.nasa.gov/citations/20190028663>>. Citado 2 vezes nas páginas 28 e 29.

FAO. *The State of Food and Agriculture 2022: Leveraging automation in agriculture for transforming agri-food systems*. Rome, 2022. Acessado em 07 nov. 2025. Disponível em: <<https://doi.org/10.4060/cb9479en>>. Citado na página 21.

FAROOQ, M. S.; AKRAM, U. Iot in agriculture: Challenges and opportunities. *Journal of Agricultural Research*, 2021. Acessado em: 12 nov. 2025. Disponível em: <<http://jaragri.com/jar/index.php/jar/article/view/180>>. Citado na página 27.

FAROOQ, M. S. et al. A survey on the role of iot in agriculture for the implementation of smart livestock environment. *IEEE Access*, v. 10, 2022. Acessado em: 13 nov. 2025. Disponível em: <<https://ieeexplore.ieee.org/document/9681084>>. Citado 2 vezes nas páginas 22 e 27.

GARCÍA-BERNÁ, J. A. et al. Systematic mapping study on remote sensing in agriculture. *Applied Sciences*, v. 10, n. 10, p. 3456, 2020. Acessado em: 15 nov. 2025. Disponível em: <<https://www.mdpi.com/2076-3417/10/10/3456>>. Citado 2 vezes nas páginas 28 e 29.

GOMES, J. P. d. T.; INNOCENTINI, M. D. M.; FORMIGONI, C. E. Utilização da iot na agricultura sustentável. *Anais da 15ª Jornada Científica e Tecnológica do IFSULDEMINAS*, v. 15, n. 3, 2023. Acessado em: 13 nov. 2025. Disponível em: <<https://josif.ifsuldeminas.edu.br/ojs/index.php/anais/article/view/855/727>>. Citado 3 vezes nas páginas 22, 23 e 25.

HUSSEIN, W. et al. Harvesting the future: Ai and iot in agriculture. In: *E3S Web of Conferences*. [s.n.], 2024. v. 477, p. 00090. Acessado em: 15 nov. 2025. Disponível em: <https://www.e3s-conferences.org/articles/e3sconf/abs/2024/07/e3sconf_star2024_00090-/e3sconf_star2024_00090.html>. Citado na página 27.

KUMAR, P. et al. A comprehensive review on smart and sustainable agriculture using iot technologies. *Smart Agricultural Technology*, v. 6, p. 100401, 2024. Acessado em: 13 nov. 2025. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2772375524000923>>. Citado 3 vezes nas páginas 22, 23 e 27.

MANCINI, M. *Internet das coisas: história, conceitos, aplicações e desafios*. São Paulo: [s.n.], 2017. Acessado em: 13 nov. 2025. Disponível em: <<http://mmproject.com.br/wp-content/uploads/2020/02/artigo-iot-monicamancini-v1.pdf>>. Citado na página 27.

MASCHIETTO, L. G. et al. *Arquitetura e infraestrutura de IoT*. Porto Alegre: SAGAH, 2021. ISBN 978-65-5690-194-7. Citado na página 27.

MUTURI, J. W.; NDEHEDEHE, C. E.; KENNARD, M. J. A review of the use of remote sensing techniques in assessing irrigation water use. *Agricultural Water Management*, v. 319, p. 109759, 2025. Acessado em: 18 nov. 2025. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0378377425004731>>. Citado 3 vezes nas páginas 23, 24 e 25.

REJEB, A. et al. The interplay between the internet of things and agriculture: A bibliometric analysis and research agenda. *Internet of Things*, v. 20, p. 100607, 2022. Acessado em: 15 nov. 2025. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2542660522000701>>. Citado na página 27.

ROCHA, L. O. d. S.; GUIMARÃES, C. R. R.; OLIVEIRA, R. A. P. d. Exploração do uso eficiente de recursos hídricos na agricultura: investigação de técnicas de irrigação e tecnologias para a minimização do desperdício de água. *Revista Foco*, v. 17, n. 4, p. e4950, 2024. Acessado em 07 nov. 2025. Disponível em: <<https://doi.org/10.54751/revistafoco.v17n4-128>>. Citado 3 vezes nas páginas 21, 23 e 25.

RODRIGUES, H. et al. Remote and proximal sensors data fusion: Digital twins in irrigation management zoning. *Sensors*, v. 24, p. 5742, 2024. Acessado em: 18 nov. 2025. Disponível em: <<https://doi.org/10.3390/s24175742>>. Citado 2 vezes nas páginas 24 e 25.

ROY, D. P. et al. Field-scale root-zone soil moisture retrieval using sentinel-1 sar: a review and perspectives. *Sensors*, v. 25, n. 10, p. 3065, 2025. Acessado em: 15 nov. 2025. Disponível em: <<https://www.mdpi.com/1424-8220/25/10/3065>>. Citado na página 28.

TRINTA, M. A.; CESAR, F.; PANTOJA, C. E. Gerenciamento autônomo de uma agricultura utilizando sistema multiagente em uma arquitetura iot. *Revista Eletrônica de Iniciação Científica em Computação*, v. 19, n. 1, 2021. Acessado em: 18 nov. 2025. Disponível em: <<https://journals-sol.sbc.org.br/index.php/reic/article/view/1777>>. Citado 2 vezes nas páginas 23 e 25.

WANG, J. et al. Integration of remote sensing and machine learning for precision agriculture: A comprehensive perspective on applications. *Agronomy*, v. 14, p. 1975, 2024. Acessado em 08 nov. 2025. Disponível em: <<https://doi.org/10.3390/agronomy14091975>>. Citado 3 vezes nas páginas 21, 24 e 25.

Apêndices

APÊNDICE A – Título do Apêndice

Anexos

ANEXO A – Título do Anexo